

Pencarian Terpadu Tahan Salah Ketik pada Rekam Medis Elektronik Sumber Terbuka: TF-IDF Hibrida Kata-Karakter dengan Fusi Peringkat Berbobot pada OpenMRS

Stephen Prasetya Chrismawan	25/563032/PPA/07093
M. Syarif Hidayatullah	25/567018/PPA/07143
Sampurno Aji	25/568826/PPA/07155
Reza Purwantara Firdaus	25/565168/PPA/07125

Abstrak—Latar belakang. OpenMRS adalah rekam medis elektronik sumber terbuka yang banyak dipakai di fasilitas kesehatan berdaya rendah. Kotak pencariannya menjadi pintu masuk hampir seluruh alur kerja klinis, namun hanya entitas konsep yang memiliki pencarian tahan salah ketik; tujuh entitas lain tidak memilikinya sama sekali, dan tidak ada satu pun kotak pencarian yang menjangkau seluruhnya. Tujuan. Merancang, mengimplementasikan, dan mengevaluasi mesin pencarian terpadu lintas-entitas yang tahan salah ketik, cukup ringan untuk dijalankan tanpa GPU, tanpa server indeks terpisah, dan tanpa sambungan internet. Metode. Delapan tabel OpenMRS diproyeksikan ke satu bentuk dokumen virtual, lalu diindeks dua kali: sebagai token kata dan sebagai kepingan karakter empat-gram, keduanya dengan pembobotan TF-IDF skema *l_{tc}*. Skor kedua jalur digabung pada tingkat entitas (bobot jalur kata 0,20), lalu peringkat antar-entitas disatukan dengan *Weighted Reciprocal Rank Fusion*. Sistem diuji pada 360 kueri sintesis berlabel atas korpus 8.045 dokumen (35.914 *surface form*) demo data resmi OpenMRS, dengan pemisahan ketat 100 kueri pengembangan dan 260 kueri uji yang hanya dijalankan sekali. Signifikansi diukur dengan *paired bootstrap*. Hasil. Sistem usulan mencapai $nDCG@10$ 0,670 terhadap 0,631 milik baseline pencocokan awalan — selisih +0,039 yang tidak mencapai signifikansi ($p=0,079$). Keunggulan yang bertahan berada pada dimensi lain: kueri tanpa hasil turun dari 15,4% menjadi 0,0%, $R@10$ naik dari 0,594 menjadi 0,743, dan MRR dari 0,725 menjadi 0,780. Ablasi menempatkan seluruh perolehan itu pada satu komponen, kepingan karakter (E1 vs B1 +0,114, $p<0,001$), sedangkan fusi peringkat berbobot tidak menyumbang $nDCG$ (−0,011, $p=0,406$). Analisis per entitas menjelaskan sebabnya: sistem usulan unggul jelas pada entitas berciri kamus (konsep +0,171, obat +0,232) dan kalah pada entitas instans per-

pasien yang judulnya berulang lintas baris (hasil laboratorium −0,180, pasien −0,242). Terhadap endpoint pencarian konsep OpenMRS yang sesungguhnya, selisihnya +0,055 ($p=0,269$), juga tidak signifikan. Implementasi Java mereproduksi angka Python (b0 dan e3 cocok persis), membangun 17 indeks dalam 2,08 detik, dan melayani kueri pada p95 50 ms. Simpulan. Kepingan karakter menghapus jalan buntu pencarian secara meyakinkan, tetapi keunggulan $nDCG@10$ -nya tidak bertahan begitu korpus diperluas ke entitas instans per-pasien. Manfaat metode ini bergantung pada sifat entitas yang diindeks, bukan berlaku merata — temuan yang hanya terlihat karena korpus evaluasi disamakan dengan korpus yang benar-benar dipasang.

Kata Kunci—Perolehan informasi, rekam medis elektronik, OpenMRS, TF-IDF, kepingan karakter (*n*-gram), fusi peringkat resiprokal, toleransi salah ketik, informatika kesehatan sumber terbuka.

I. INTRODUCTION

REKAM medis elektronik (RME) sumber terbuka telah menjadi tulang punggung digitalisasi layanan kesehatan di negara berpenghasilan rendah dan menengah. OpenMRS, yang lahir pada 2004 sebagai kolaborasi antara Regenstrief Institute dan Partners In Health, dirancang secara eksplisit untuk konteks tersebut: dapat dipasang pada perangkat keras sederhana, dikelola oleh tim kecil, dan diperluas melalui modul [1], [2]. Ia kini dipakai pada ribuan fasilitas di puluhan negara, dari klinik kabupaten sampai rumah sakit rujukan [3], [4], dalam ekosistem *e-health* berbiaya rendah yang tumbuh cepat namun tetap dibatasi oleh keterbatasan daya komputasi dan konektivitas [5].

A. Pencarian sebagai pintu masuk alur kerja klinis

Pada RME, hampir setiap tindakan bermula dari sebuah kotak pencarian. Klinisi mencari konsep untuk menegakkan diagnosis, mencari obat untuk menulis resep, mencari pasien untuk membuka rekam, mencari hasil laboratorium untuk menilai perkembangan. Analisis atas kueri nyata pada utilitas pencarian RME menunjukkan bahwa pencarian bukan aktivitas

Naskah diserahkan 3 September 2026. Penelitian ini dilaksanakan tanpa pendanaan eksternal. Seluruh perangkat lunak, data eksperimen, dan berkas hasil mentah yang mendasari angka pada naskah ini tersedia pada repositori penelitian yang sama dengan naskah ini.

S. P. Chrismawan (NIM 25/563032/PPA/07093; e-mail: stephenprasetyachrismawan27@gmail.com), M. S. Hidayatullah (NIM 25/567018/PPA/07143), S. Aji (NIM 25/568826/PPA/07155), dan R. P. Firdaus (NIM 25/565168/PPA/07125) adalah mahasiswa Program Studi Ilmu Komputer, Program Pascasarjana.

Kode implementasi modul OpenMRS berada pada `backend/openmrs-module-tfidf-search/`; skrip eksperimen dan berkas hasil mentah pada `riset/`.

periferal melainkan aktivitas inti, dan bahwa kegagalan pencarian berujung pada pengabaian alur kerja atau pemasukan data yang tidak terstandar [6]. Pengalaman sembilan tahun pengembangan EMERSE di University of Michigan sampai pada kesimpulan senada: kualitas mesin pencarian menentukan apakah data yang sudah tersimpan benar-benar dapat dipakai kembali [7].

Beban kognitif dan tekanan waktu di ruang praktik membuat kueri yang diketik klinisi jauh dari sempurna. Kesalahan pengetikan pada dokumen klinis bebas terdokumentasi dengan baik dan berjumlah besar [8]; pada kueri pencarian kesehatan, kesalahan ejaan bahkan lebih sering karena kueri pendek dan diketik terburu-buru [9], [10]. Taksonomi klasik Kukich membedakan kesalahan tipografis (jari meleset) dari kesalahan kognitif (ejaan tidak diketahui) [11]; keduanya hadir bersamaan dalam terminologi medis yang panjang, berbahasa Latin, dan jarang dipakai dalam percakapan sehari-hari. Istilah seperti *cholecystectomy* atau *pyelonephritis* menggabungkan kedua sumber kesalahan sekaligus.

B. Celah pada OpenMRS

Pemeriksaan langsung terhadap instalasi OpenMRS Reference Application yang berjalan — bukan pembacaan dokumentasi — mengungkap dua celah yang saling menguatkan.

Pertama, toleransi salah ketik tidak merata. OpenMRS menyediakan endpoint pencarian konsep dengan mode *fuzzy* berbasis Lucene (`GET /ws/rest/v1/concept?searchType=fuzzy`) yang bekerja cukup baik. Namun mode itu hanya melayani entitas konsep. Pencarian obat, pasien, formulir, lokasi, penyedia layanan, hasil laboratorium, dan kondisi tetap bertumpu pada pencocokan awalan atau substring pada basis data relasional. Konsekuensinya konkret: kueri "amoxicilin" (satu huruf kurang) menemukan konsep, tetapi tidak menemukan sediaan obat yang justru dibutuhkan untuk menulis resep.

Kedua, tidak ada pencarian terpadu. Setiap entitas memiliki kotak pencariannya sendiri pada halaman yang berbeda. Klinisi yang mengetik "diabetes" harus memutuskan lebih dahulu apakah yang dicari adalah konsep, obat, atau pasien — padahal pada banyak situasi klinis keputusan itu justru merupakan hasil yang diharapkan dari pencarian, bukan prasyaratnya.

C. Mengapa solusi berat bukan jawaban di sini

Perolehan informasi modern menawarkan jawaban yang kuat untuk ketidakcocokan leksikal: pemeringkat berbasis *transformer* terlatih [34], representasi laten seperti ColBERT [35], dan model jarang terpelajar seperti SPLADE [36]. Semuanya menuntut akselerator, memori besar, dan — bagi kebanyakan puskesmas — sambungan internet untuk mengunduh dan memperbarui bobot model. Biaya komputasi dan energinya pun tidak dapat diabaikan [37]. Untuk fasilitas yang menjadi sasaran OpenMRS, prasyarat itu menghapus solusi tersebut dari daftar pilihan sebelum evaluasi mutu dimulai.

Sebaliknya, kepustakaan perolehan informasi klasik menyediakan mekanisme yang justru dirancang untuk ketidakcocokan pada tingkat karakter. Kepingan karakter (*n*-gram) terbukti

tangguh menghadapi variasi morfologis dan kesalahan ejaan lintas bahasa [16], memiliki dasar teoretis pada pencocokan string aproksimatif [14], [15], dan dapat diindeks secara efisien [17]. Pembobotan TF-IDF dengan normalisasi kosinus [18]–[21] dan fusi peringkat resiprokal [24] adalah teknik matang yang berjalan pada CPU biasa. Pertanyaannya bukan apakah teknik-teknik itu ada, melainkan seberapa jauh kombinasinya memadai untuk masalah nyata ini, komponen mana yang sebenarnya bekerja, dan — pertanyaan yang ternyata paling menentukan — pada jenis data seperti apa manfaatnya berlaku.

D. Rumusan masalah

Dari uraian di atas, penelitian ini merumuskan empat pertanyaan.

- RQ1** Seberapa besar peningkatan mutu peringkat yang dapat dicapai mesin pencarian terpadu lintas-entitas berbasis TF-IDF hibrida kata-karakter dibandingkan baseline pencocokan awalan bergaya antarmuka OpenMRS?
- RQ2** Di antara komponen yang diusulkan — kepingan karakter, fusi tingkat entitas, fusi peringkat berbobot, dan perluasan kueri — komponen mana yang benar-benar menyumbang peningkatan, dan sebesar apa?
- RQ3** Apakah keunggulan itu bertahan ketika pembandingnya bukan tiruan heuristik buatan sendiri, melainkan endpoint pencarian OpenMRS yang sesungguhnya?
- RQ4** Apakah sistem yang diusulkan cukup ringan untuk dipasang sebagai modul OpenMRS pada perangkat keras biasa, dan apakah implementasinya mereproduksi hasil eksperimen secara numerik?

E. Tujuan penelitian

Menjawab empat pertanyaan tersebut, tujuan penelitian ini adalah: (1) merancang mesin pencarian terpadu yang memproyeksikan delapan tabel OpenMRS ke satu ruang dokumen dan memeringkatnya dengan TF-IDF hibrida kata-karakter serta fusi peringkat berbobot; (2) mengukur kontribusi setiap komponen secara terpisah melalui ablasi dengan uji signifikansi, bukan melalui argumen; (3) membandingkan sistem terhadap dua baseline — satu tiruan pencocokan awalan dan satu endpoint OpenMRS asli — serta melaporkan selisih keduanya apa adanya; dan (4) mengimplementasikan rancangan itu sebagai modul OpenMRS (.omod) yang dapat dipasang, lalu memverifikasi bahwa implementasinya mereproduksi angka eksperimen.

F. Kontribusi

Naskah ini menyumbangkan lima hal.

- 1) **Rancangan pencarian terpadu lintas-entitas** yang memproyeksikan delapan tabel OpenMRS ke satu kontrak dokumen virtual, sehingga mesin peringkat tidak lagi mengetahui asal tabel sebuah hasil.
- 2) **Temuan bahwa manfaat kepingan karakter bergantung pada sifat entitas.** Metode ini unggul jelas pada entitas berciri kamus dan justru kalah pada entitas instans per-pasien yang judulnya berulang lintas baris.

Sepanjang pengetahuan kami, ketergantungan ini belum pernah dilaporkan secara kuantitatif pada konteks RME.

- 3) **Ablasi komponen yang jujur.** Dari empat komponen yang diusulkan, hanya kepingan karakter yang menyumbang perolehan terukur; fusi peringkat berbobot tidak menaikkan nDCG, dan perluasan kueri justru memperburuk hasil.
- 4) **Koreksi baseline.** Baseline pencocokan awalan buatan sendiri, yang lazim dipakai sebagai proksi “pencarian bawaan”, terbukti *lebih lemah* daripada pencarian OpenMRS yang sesungguhnya; kami melaporkan penurunan besaran klaim yang mengikutinya.
- 5) **Implementasi yang dapat dipasang dan terverifikasi silang.** Modul Java mereproduksi pipeline Python pada korpus yang sama persis, membangun indeks dalam 2,08 detik, dan melayani kueri pada p95 50 ms.

G. Sistematika

Bagian II memaparkan rancangan sistem, korpus, protokol evaluasi, dan implementasi. Bagian III menyajikan hasil pengukuran. Bagian IV menafsirkan hasil, mengakui keterbatasan, dan menutup dengan simpulan.

II. METHODS

A. Desain penelitian dan lingkungan

Penelitian ini berbentuk penelitian rekayasa perangkat lunak dengan evaluasi kuantitatif berbasis korpus. Rancangan diuji dua kali secara independen: sebagai *reference implementation* Python untuk pengukuran eksperimental, dan sebagai modul OpenMRS berbahasa Java untuk pembuktian kelayakan pemasangan. Kedua implementasi dibandingkan secara numerik pada korpus yang sama persis.

Data berasal dari demo data resmi OpenMRS Reference Application yang berjalan di atas MariaDB dalam kontainer Docker. Data ini merupakan sebaran resmi proyek, bukan data pasien nyata, sehingga eksperimen tidak menyentuh informasi kesehatan yang dapat diidentifikasi. Seluruh pengukuran dilakukan pada satu mesin komputer pribadi tanpa akselerator grafis.

B. Cakupan entitas: korpus evaluasi disamakan dengan korpus terpasang

Keputusan metodologis yang paling menentukan pada penelitian ini adalah menyamakan cakupan korpus evaluasi dengan cakupan modul yang benar-benar dipasang. Versi awal pipeline penelitian hanya mengindeks enam entitas, sementara modul yang terpasang mengindeks delapan; akibatnya angka yang dilaporkan tidak menggambarkan sistem yang dijalankan pengguna. Seluruh angka pada naskah ini karena itu dihasilkan atas **delapan entitas**, dengan daftar dan urutan yang diambil langsung dari konstanta di dalam kode modul. Konsekuensinya diuraikan terbuka pada Bagian IV: sebagian klaim yang bertahan pada korpus enam entitas tidak bertahan pada korpus penuh.

C. Kontrak dokumen virtual

Delapan tabel OpenMRS — *concept*, *drug*, *patient*, *form*, *location*, *provider*, *obs* (hasil laboratorium), dan *conditions* — diproyeksikan ke satu bentuk dokumen virtual dengan medan: *entitas*, *id*, *judul*, *alias*, *kode*, *konteks*, dan *tautan opsional*. Kunci unik lintas tabel dibentuk sebagai *entitas:id*, misalnya *konsep:5497*. Setelah proyeksi ini mesin peringkat tidak lagi mengetahui tabel asal sebuah dokumen; seluruh perbedaan perlakuan antar-entitas terjadi secara eksplisit pada tahap fusi.

Medan konteks sengaja *tidak* diindeks. Ia hanya ditampilkan. Memasukkannya akan mencemari statistik IDF dengan kata-kata berfrekuensi tinggi yang tidak membedakan, seperti “tablet” atau “Diagnosis”.

D. Surface form

Setiap dokumen dipecah menjadi beberapa unit pencarian terpisah yang disebut *surface form*: judul menghasilkan satu unit, setiap elemen *alias* menghasilkan satu unit, dan setiap elemen *kode* menghasilkan satu unit. Dokumen *Diabetes mellitus, type 2* dengan tiga sinonim dan dua kode menghasilkan enam *surface form*. Skor sebuah dokumen adalah skor *tertinggi* di antara *surface form* miliknya — bukan rata-rata dan bukan jumlah — sehingga dokumen dengan banyak sinonim tidak diuntungkan hanya karena jumlahnya. Perlakuan ini juga menjaga agar kode terminologi seperti kode LOINC [33] dapat dicari langsung tanpa mencemari statistik teks judul.

E. Normalisasi dan dua cara pemotongan

Normalisasi teks mengubah huruf menjadi kecil dan mengganti setiap deret karakter non-alfanumerik menjadi satu spasi. Dari teks ternormalisasi dibentuk dua representasi berbeda.

Token kata diperoleh dengan memisah pada spasi. *Kepingan karakter* diperoleh dengan mengganti spasi menjadi garis bawah, lalu menggeser jendela sepanjang $n = 4$ karakter satu posisi demi satu posisi:

"pulm edem" → "pulm_edem" → {pulm, ulm_, lm_e, m_ed

Bila teks lebih pendek daripada n , teks itu sendiri dikembalikan sebagai satu kepingan, agar entri pendek tetap dapat ditemukan. Penggantian spasi dengan garis bawah bersifat disengaja: batas kata ikut menjadi sinyal, sehingga *_ede* (awal kata *edema*) berbeda dari *nede* (di tengah kata). Inilah mekanisme yang membuat representasi kepingan tahan terhadap kesalahan sisipan, penghapusan, dan transposisi [12], [13] tanpa perlu menghitung jarak edit secara eksplisit.

F. Pembobotan TF-IDF skema ltc

Kedua representasi dibobot dengan skema SMART *ltc* [19]: bobot frekuensi logaritmik, IDF, dan normalisasi kosinus. Untuk term t pada *surface form* d dari koleksi berukuran N

surface form,

$$\text{tf}(t, d) = 1 + \log f_{t,d}, \quad (1)$$

$$\text{idf}(t) = \log \frac{N}{\text{df}(t)} + 1, \quad (2)$$

$$w_{t,d} = \frac{\text{tf}(t, d) \cdot \text{idf}(t)}{\sqrt{\sum_{t' \in d} (\text{tf}(t', d) \cdot \text{idf}(t'))^2}}. \quad (3)$$

Vektor kueri dibangun dengan cara yang sama menggunakan IDF dari indeks yang sedang dipakai, dan kemiripan dihitung sebagai hasil kali titik dua vektor ternormalisasi, yang setara dengan kosinus [18]. Basis logaritma tidak memengaruhi peringkat selama konsisten; kami memakai logaritma natural agar angka Python dan Java dapat dibandingkan langsung.

G. Tujuh belas indeks

Untuk setiap entitas dibangun dua indeks terbalik — satu untuk token kata, satu untuk kepingan karakter — sehingga delapan entitas menghasilkan enam belas indeks. Satu indeks *global* tambahan dibangun atas gabungan seluruh surface form kedelapan entitas, menjadikan total tujuh belas. Indeks *global* hanya dipakai untuk menghitung bobot entitas pada tahap fusi tingkat dua; ia tidak pernah dipakai untuk memeringkat hasil.

H. Fusi tingkat satu: kata dan kepingan

Di dalam satu entitas, skor kedua jalur digabung secara linier. Misalkan $s_W(d)$ dan $s_G(d)$ adalah kosinus maksimum dokumen d pada indeks kata dan indeks kepingan; skor gabungan adalah

$$s(d) = \alpha s_W(d) + (1 - \alpha) s_G(d), \quad \alpha = 0,20. \quad (4)$$

Urutan operasi penting dan bersifat mengikat: maksimum atas surface form diambil *di dalam* masing-masing jalur, baru kedua hasilnya digabung. Pengukuran pada 780 kueri terdegradasi menunjukkan bahwa membalik urutan ini mengubah skor pada 47,4% kueri dan mengubah komposisi sepuluh besar pada 17,8% kueri; implementasi Java karena itu disamakan dengan urutan pipeline penelitian. Dokumen dengan $s(d) \leq 10^{-6}$ dibuang.

I. Fusi tingkat dua: Weighted Reciprocal Rank Fusion

Fusi peringkat resiprokal (RRF) menggabungkan beberapa daftar peringkat tanpa memerlukan kalibrasi skor antar daftar [24], sifat yang penting di sini karena skor kosinus delapan entitas berukuran koleksi sangat berbeda tidak sebanding secara langsung [23]. RRF baku memperlakukan seluruh daftar setara. Kami memberinya bobot yang diturunkan dari indeks global.

Untuk kueri q , misalkan g_e adalah skor tertinggi yang dicapai suatu surface form milik entitas e pada indeks global. Bobot entitas dihitung sebagai

$$w_e = \varepsilon + (1 - \varepsilon) \frac{g_e}{\sum_{e'} g_{e'}}, \quad \varepsilon = 0,05, \quad (5)$$

dengan $w_e = 1$ untuk seluruh e bila $\sum_{e'} g_{e'} = 0$. Suku ε berfungsi sebagai lantai: tanpanya, entitas yang skor globalnya

nol memperoleh bobot nol dan hasilnya hilang sama sekali, padahal ia mungkin masih relevan. Skor akhir sebuah dokumen d pada entitas e yang menempati peringkat r di dalam entitasnya sendiri adalah

$$\text{RRF}_w(d) = w_e \cdot \frac{1}{k + r}, \quad k = 20. \quad (6)$$

Perumusan bobot semacam ini sejalan dengan analisis fungsi fusi pada perolehan hibrida, yang menunjukkan bahwa pembobotan berbasis peringkat lebih stabil daripada penjumlahan skor mentah ketika distribusi skor antar-sistem berbeda [25].

J. Determinisme

Pengurutan akhir memakai kunci majemuk (–skor, kunci unik), bukan skor saja. RRF menghasilkan banyak nilai yang persis sama, dan tanpa pemecah seri yang stabil hasilnya berubah antar-proses. Iterasi atas himpunan selalu diurutkan lebih dahulu; implementasi Java memakai `TreeMap/TreeSet` dan perbandingan majemuk eksplisit, tidak pernah mengandalkan urutan `HashMap`. Kriteria uji yang dipakai adalah kesetaraan angka sampai digit terakhir pada dua proses yang berbeda.

K. Jalur saran ketik

Terpisah dari jalur peringkat, sistem menyediakan endpoint saran ketik (“Maksud Anda”) yang menawarkan dokumen kandidat ketika kueri tampak salah eja. Ini adalah perluasan kueri interaktif dalam pengertian Ruthven: sistem menawarkan, pengguna memutuskan [26]. Skor saran memakai koefisien Jaccard [27] atas himpunan bigram karakter,

$$J(q, f) = \frac{|B_2(q) \cap B_2(f)|}{|B_2(q) \cup B_2(f)|}, \quad (7)$$

dengan $B_2(\cdot)$ himpunan bigram karakter teks ternormalisasi. Surface form hanya diskor bila $|B_2(q) \cap B_2(f)| \geq 2$, kecuali bila kedua himpunan bigram identik. Bigram ($n = 2$) dipakai di sini, bukan empat-gram seperti pada jalur peringkat, karena kueri yang sangat pendek tidak menghasilkan cukup empat-gram untuk dicocokkan. Skor dokumen adalah skor tertinggi surface form-nya, dengan surface form judul memenangi seri terhadap alias dan kode.

L. Sistem yang dibandingkan

Tujuh sistem dievaluasi berdampingan pada korpus dan kueri yang sama (Tabel I).

B0 bekerja dua tahap. Tahap penyaringan meloloskan sebuah surface form hanya bila setiap kata kueri menjadi awalan bagi sekurang-kurangnya satu kata pada surface form itu. Tahap pemberian skor menambahkan 1000 untuk kecocokan persis setelah normalisasi, 500 bila surface form adalah judul, 200 untuk setiap kata kueri yang muncul utuh dan 100 untuk kecocokan awalan saja, lalu mengurangi 0,6 per karakter panjang teks sebagai penalti panjang. B0 bukan sistem yang lemah secara sengaja; ia justru unggul pada kueri terpotong, dan diimplementasikan apa adanya tanpa diperlemah.

B2 memakai BM25 [22] dengan $k_1 = 1,2$ dan $b = 0,75$ pada indeks kata, disertakan agar perbandingan tidak hanya

TABLE I
SISTEM YANG DIBANDINGKAN

Kode	Deskripsi
B0	Pencocokan awalan bergaya antarmuka lawas, skor mentah
B0'	Endpoint pencarian konsep OpenMRS asli (<i>fuzzy Lucene</i>)
B1	TF-IDF token kata, skor mentah
B2	BM25 token kata, skor mentah
E1	TF-IDF hibrida kata + kepingan, skor mentah
E2	E1 + RRF baku (tanpa bobot entitas)
E3	E1 + Weighted RRF (sistem usulan)
E4	E3 + perluasan kueri otomatis (<i>pseudo-relevance feedback</i>)

melawan TF-IDF. *E4* melakukan pass pertama dengan *E3*, mengambil sinonim dan kode dari lima dokumen teratas, menambahkannya ke kueri, lalu menjalankan pass kedua.

B0' adalah baseline yang paling penting secara metodologis. Ia bukan tiruan, melainkan endpoint OpenMRS yang sesungguhnya, dipanggil langsung terhadap server yang berjalan:

```
GET /ws/rest/v1/concept?name={q}&searchType=fuzzy
&limit=50&v=custom:(uuid,display)
```

Karena endpoint *fuzzy* OpenMRS hanya melayani konsep, *B0'* hanya dapat diukur pada subhimpunan kueri konsep. Keterbatasan ini sendiri merupakan temuan: tujuh entitas lain tidak memiliki padanan pencarian tahan salah ketik di OpenMRS sama sekali.

Dua catatan metodologis dicatat pada pengukuran *B0'*. *Pertama*, parameter *locale* eksplisit pada URL ternyata merusak pencarian — endpoint mengembalikan daftar tetap yang tidak berkaitan untuk setiap kueri — sehingga *locale* dipatok melalui sesi dan dikonfirmasi pada setiap eksekusi. *Kedua*, *uuid* hasil dipetakan ke *concept_id* melalui kueri SQL langsung, dan hasil di-*dedupe* sebelum dipotong ke sepuluh besar.

M. Kueri uji dan standar emas

Karena tidak tersedia log kueri klinisi nyata untuk instalasi ini, kueri dibangkitkan secara sintesis namun deterministik dari judul dokumen korpus (*seed* = 42). Rencana pengambilan sampel mengikuti proporsi entitas: 110 konsep, 80 obat, 60 pasien, 40 lokasi, 40 hasil laboratorium, 40 kondisi, 10 formulir, dan 6 penyedia layanan. Untuk konsep, hanya kelas klinis yang diambil (Diagnosis, Symptom, Finding, Procedure, Test, Anatomy, Drug).

Kuota hasil laboratorium dan kondisi sengaja ditetapkan 40, jauh di bawah porsi dokumennya. Alasannya struktural dan penting untuk penafsiran hasil: kedua entitas itu berisi *instans per-pasien*, sehingga judulnya berulang lintas baris. Kuota sebesar porsi dokumen hanya akan menggandakan judul yang sama berkali-kali tanpa menambah keragaman kueri.

Setiap judul terpilih didegradasi dengan salah satu dari lima jenis gangguan yang digelar secara bergantian:

- *persis* — judul apa adanya, kontrol langit-langit;
- *typo* — pada satu kata sepanjang ≥ 5 huruf, satu huruf di posisi tengah dihapus atau ditukar dengan tetangganya, meniru kesalahan tipografis [12];

- *trunkasi* — setiap kata lebih dari 5 huruf dipotong menjadi 4–5 huruf, meniru pengetikan yang sengaja dipersingkat;
- *hilang_kata* — satu kata dihapus dari frasa;
- *urut_balik* — urutan kata dibalik.

Standar emas dibangun otomatis dari struktur data OpenMRS, bukan dari penilaian manual, dan memakai **dua model relevansi** sesuai sifat entitasnya.

Untuk enam entitas berciri kamus, relevansi diturunkan dari tautan struktural. Dokumen sumber kueri memperoleh gradasi 2; gradasi 1 diberikan kepada dokumen yang tertaut — untuk konsep, seluruh sediaan obat yang menunjuk ke konsep itu serta konsep lain yang berbagi kode referensi terminologi non-CIEL; untuk obat, konsep induknya dan sediaan lain dari konsep yang sama.

Untuk hasil laboratorium dan kondisi, model itu tidak berlaku. Judul kedua entitas ini berulang lintas pasien: 2.018 hasil laboratorium hanya memuat 203 judul unik (“Haemoglobin” muncul 37 kali), dan 1.279 kondisi memuat 386 judul unik. Dokumen sumber tetap memperoleh gradasi 2, tetapi seluruh dokumen sejenis yang judulnya sama setelah normalisasi memperoleh gradasi 1. Tanpa aturan ini metrik akan mengukur pemecah seri kunci, bukan mutu peringkat: kueri “Haemoglobin” punya 37 jawaban yang sama sahnya, dan menghukum 36 di antaranya tidak mencerminkan kepuasan pengguna.

Proses ini menghasilkan 360 kueri berlabel.

N. Protokol pemisahan dev/test

Setelah diacak dengan *seed* yang sama, kueri dibagi menjadi 100 kueri pengembangan (*dev*) dan 260 kueri uji (*test*). Seluruh penyetelan parameter — α , n , k , dan ε — dilakukan *eksklusif* pada 100 kueri *dev*. Himpunan uji dijalankan *satu kali* setelah seluruh parameter dikunci.

Protokol ini ditegakkan setelah temuan serius dalam penelitian ini sendiri: sapuan parameter versi awal secara keliru dijalankan pada himpunan uji, sehingga seluruh tabel sapuan pada dokumen proposal tercemar. Skrip tersebut dipertahankan sebagai arsip dan tidak dijalankan kembali; seluruh angka sapuan pada naskah ini berasal dari sapuan ulang pada himpunan *dev*. Kami melaporkan pelanggaran ini secara terbuka karena menyembunyikannya akan membuat angka uji tidak dapat ditafsirkan sebagai ukuran independen.

O. Metrik

Metrik utama adalah $nDCG@10$ dengan gain eksponensial [28],

$$DCG@10 = \sum_{r=1}^{10} \frac{2^{g_r} - 1}{\log_2(r + 2)}, \quad nDCG@10 = \frac{DCG@10}{IDCG@10}, \quad (8)$$

dengan $g_r \in \{0, 1, 2\}$ gradasi relevansi dokumen pada peringkat r . Metrik pendamping adalah $P@1$, $P@5$, $R@10$, MRR , MAP , dan proporsi kueri tanpa hasil sama sekali. Metrik terakhir dilaporkan karena dalam konteks klinis layar kosong merupakan mode kegagalan yang berbeda secara kualitatif dari hasil yang buruk: ia menghentikan alur kerja alih-alih

memperlambatnya [32]. Pada penelitian ini metrik itu ternyata menjadi pembeda yang paling menentukan.

P. Uji signifikansi

Selisih $nDCG@10$ antar-sistem diuji dengan *paired bootstrap* [29], metode yang direkomendasikan untuk evaluasi perolehan informasi karena tidak mengandaikan normalitas dan menghormati struktur berpasangan per-kueri [30], [31]. Setiap uji memakai 5.000 resampel dengan $seed = 7$; dilaporkan selisih teramati, selang kepercayaan 95%, dan nilai p dua sisi dari distribusi yang dipusatkan.

Kami tidak menerapkan koreksi perbandingan berganda, dan menyatakan hal ini secara eksplisit karena berpengaruh pada penafsiran: perbandingan dengan p mendekati 0,05 pada naskah ini harus dibaca sebagai signifikan secara nominal saja.

Q. Implementasi sebagai modul OpenMRS

Rancangan diimplementasikan sebagai modul OpenMRS (.omod) berbahasa Java dengan sasaran bytecode Java 8. Modul membangun ketujuh belas indeks di memori satu kali pada saat OpenMRS mulai berjalan, lalu menyediakan tiga endpoint REST: satu untuk pencarian dengan parameter mode bernilai $b0$, $b1$, $e1$, atau $e3$ (bawaan $e3$), satu untuk saran ketik, dan satu untuk menjalankan evaluasi. Setiap komponen dapat dimatikan melalui parameter atau properti global — bukan sebagai fitur pengguna, melainkan sebagai prasyarat agar kontribusi tiap komponen dapat diukur ulang kapan saja.

Verifikasi silang dilakukan berlapis. Pada tingkat korpus, jumlah dokumen, jumlah surface form, dan jumlah indeks dibandingkan antara Java yang berjalan di server dan Python yang menghitung ulang dari berkas korpus. Pada tingkat sistem, endpoint evaluasi Java dijalankan atas 100 kueri dev dengan standar emas yang sama persis — diekspor dari pipeline Python ke berkas sumber daya modul dan diverifikasi melalui SHA-256 — lalu $nDCG@10$ -nya dibandingkan dengan angka Python.

Verifikasi tingkat sistem ini sendiri mengoreksi satu kekeliruan: upaya awal membangkitkan ulang kueri dev di dalam Java dengan `java.util.Random(42)` tidak mungkin cocok, karena `java.util.Random` adalah LCG 48-bit sedangkan `random.Random` Python adalah Mersenne Twister. Kesenjangan yang semula tampak sebagai selisih algoritma peringkat ternyata sepenuhnya merupakan selisih pembangkit kueri.

R. Hak akses pasien

Indeks dibangun dari seluruh data, tetapi hasil disaring per pengguna sebelum dikembalikan. Endpoint memeriksa privilege OpenMRS pemanggil (`Context.hasPrivilege("View Patients")`) dan membuang seluruh hasil berjenis pasien, hasil laboratorium, dan kondisi bila privilege itu tidak dimiliki. Pemeriksaan ini berlaku juga di lingkungan uji.

S. Eksperimen jalur saran ketik

Jalur saran ketik dievaluasi secara terpisah dengan kueri sendiri, dan hasilnya tidak digabungkan dengan angka peringkat. Sebanyak 214 kueri dibangkitkan deterministik ($seed =$




Fig. 1. $nDCG@10$ tujuh sistem pada 260 kueri uji, korpus 8 entitas. Batang gelap adalah dua sistem yang memakai kepingan karakter. Jarak E1/E3 terhadap B0 jauh lebih sempit daripada pada korpus enam entitas.

20260901) dengan lima jenis degradasi, dua di antaranya khusus untuk jalur ini: *trunkasi_pendek* (judul satu sampai dua kata dipotong menjadi 4–6 huruf pertama) dan *typo_pendek* (*trunkasi_pendek* ditambah satu huruf salah).

Dua metrik dipakai. *Akurasi saran* mengukur apakah dokumen yang dimaksud muncul pada enam saran teratas ($hit@1$, $hit@3$, $hit@6$, $MRR@6$). *Penyelamatan kueri buntu* mengukur, pada kueri yang jalur peringkat tidak memberikan satu pun dokumen relevan pada sepuluh besar, apakah satu klik pada saran teratas membawa pengguna ke hasil yang relevan. Tidak ada $nDCG$ yang dilaporkan untuk jalur ini, karena jalur ini tidak menyentuh peringkat.

III. RESULTS

A. Korpus dan pembangunan indeks

Korpus akhir berisi 8.045 dokumen: 4.249 konsep, 2.018 hasil laboratorium, 1.279 kondisi, 322 obat, 100 pasien, 61 lokasi, 10 formulir, dan 6 penyedia layanan, menghasilkan 35.914 surface form. Ketimpangan ukuran antar-entitas ini — konsep hampir 700 kali lebih banyak daripada penyedia layanan — adalah alasan utama diperlukannya pembobotan pada tahap fusi antar-entitas.

Pembangunan ketujuh belas indeks memerlukan 2,19 detik pada implementasi Python dan 2,08 detik pada modul Java yang berjalan di dalam kontainer OpenMRS. Karena pembangunan berlangsung satu kali saat modul mulai, biaya ini tidak menyentuh jalur permintaan.

B. Perbandingan sistem pada himpunan uji

Tabel II dan Gambar 1 menyajikan hasil pada 260 kueri uji, dijalankan satu kali setelah parameter dikunci.

Sistem usulan E3 mencapai $nDCG@10$ 0,670 terhadap 0,631 milik baseline pencocokan awalan. Selisih +0,039 itu **tidak mencapai signifikansi** ($p = 0,079$; lihat Tabel III).

Perbedaan yang tegas justru muncul pada metrik lain. Baseline B0 meninggalkan **15,4% kueri tanpa hasil sama sekali** — lebih dari satu dari tujuh kueri berakhir pada layar kosong — sedangkan seluruh varian yang memakai kepingan karakter

TABLE II

HASIL PADA HIMPUNAN UJI (260 KUERI, KORPUS 8 ENTITAS, SEKALI JALAN, PARAMETER TERKUNCI). LATENSI ADALAH RERATA PER KUERI PADA IMPLEMENTASI PYTHON.

Sistem	Deskripsi	P@1	P@5	R@10	MRR	MAP	nDCG@10	% nol-hasil	Latensi (ms)
B0	Pencocokan awalan	0,662	0,291	0,594	0,725	0,515	0,631	15,4	0,35
B1	TF-IDF kata	0,492	0,312	0,600	0,612	0,469	0,568	8,8	0,45
B2	BM25 kata	0,404	0,275	0,542	0,528	0,401	0,501	8,8	0,61
E2	E1 + RRF baku	0,108	0,198	0,638	0,376	0,231	0,385	0,0	2,03
E4	E3 + perluasan kueri	0,315	0,255	0,687	0,483	0,367	0,467	0,0	15,60
E1	TF-IDF + kepingan	0,623	0,380	0,712	0,737	0,583	0,681	0,0	2,02
E3	+ Weighted RRF (usulan)	0,681	0,332	0,743	0,780	0,525	0,670	0,0	3,50

TABLE III

ABLASI KOMPONEN PADA HIMPUNAN UJI (260 KUERI). SELISIH nDCG@10, SELANG KEPERCAYAAN 95%, DAN NILAI *p* DARI *paired bootstrap* (5.000 RESAMPEL, *SEED* = 7), TANPA KOREKSI PERBANDINGAN BERGANDA.

Perbandingan	Δ nDCG	CI 95%	<i>p</i>
B1 vs B0 (TF-IDF kata saja)	-0,064	[-0,117; -0,011]	0,021
B2 vs B0 (BM25 kata saja)	-0,130	[-0,188; -0,075]	< 0,001
E1 vs B1 (+ kepingan)	+0,114	[+0,073; +0,153]	< 0,001
E1 vs B0 (+ kepingan)	+0,050	[+0,000; +0,097]	0,045
E3 vs E1 (+ Weighted RRF)	-0,011	[-0,037; +0,014]	0,406
E3 vs E2 (bobot vs RRF baku)	+0,285	[+0,259; +0,310]	< 0,001
E2 vs B0 (RRF baku saja)	-0,246	[-0,288; -0,205]	< 0,001
E4 vs B0 (perluasan kueri)	-0,164	[-0,218; -0,112]	< 0,001
E3 vs B0 (sistem penuh)	+0,039	[-0,004; +0,082]	0,079

menurunkannya ke **0,0%**. R@10 naik dari 0,594 menjadi 0,743, dan MRR dari 0,725 menjadi 0,780.

C. Ablasi komponen dan signifikansi

Tabel III memisahkan kontribusi tiap komponen.

Hasil ablasi tegas dan tidak seimbang, tetapi arahnya berbeda dari yang lazim diklaim. Mengganti pencocokan awalan dengan TF-IDF token kata saja justru *memburukkan* hasil (-0,064; *p* = 0,021), dan BM25 lebih buruk lagi (-0,130; *p* < 0,001). Penambahan kepingan karakter di atas TF-IDF kata menyumbang +0,114 (*p* < 0,001) — inilah satu-satunya komponen dengan perolehan besar dan meyakinkan. Namun karena titik awalnya sendiri berada di bawah B0, sistem hibrida hanya berhasil menyusul dan sedikit melampaui baseline pencocokan awalan: E1 vs B0 +0,050 (*p* = 0,045, signifikan nominal), dan E3 vs B0 +0,039 (*p* = 0,079, tidak signifikan).

Penambahan fusi peringkat berbobot tidak menyumbang nDCG sama sekali (-0,011; *p* = 0,406), meskipun ia menaikkan P@1 dari 0,623 ke 0,681 dan MRR dari 0,737 ke 0,780. Pada himpunan dev, pola itu terukur lebih rinci: MRR naik bermakna (+0,059; *p* = 0,0016) sementara MAP turun bermakna (-0,059; *p* = 0,0082). Fusi berbobot dengan demikian mengangkat hasil relevan pertama tetapi memperburuk sisa daftar, dan kedua efek itu saling meniadakan pada nDCG@10.

Dua komponen jelas merugikan. RRF baku tanpa bobot entitas (E2) menurunkan nDCG@10 sebesar 0,246 di bawah baseline dan meruntuhkan P@1 ke 0,108; ia meratakan kontribusi delapan entitas berukuran sangat berbeda sehingga penyedia layanan yang hanya berisi enam dokumen memperoleh




Fig. 2. nDCG@10 menurut jenis degradasi kueri pada himpunan uji. B0 unggul di empat jenis pertama dan runtuh sepenuhnya pada kesalahan ketik di tengah kata, karena pencocokan awalan gagal segera setelah huruf pertama yang salah.

TABLE IV

nDCG@10 MENURUT JENIS DEGRADASI KUERI (HIMPUNAN UJI, 260 KUERI)

Sistem	persis	hilang kata	urut balik	trunkasi	typo
B0	0,762	0,657	0,760	0,818	0,086
B1	0,690	0,626	0,693	0,266	0,544
E1	0,690	0,636	0,707	0,671	0,713
E3	0,711	0,600	0,687	0,695	0,668

pengaruh setara dengan konsep yang berisi 4.249 dokumen. Perluasan kueri otomatis (E4) menurunkan nDCG@10 sebesar 0,164 sekaligus melipatgandakan latensi tujuh kali. Komponen ini dibuang dari sistem akhir.

D. Kinerja per jenis degradasi

Gambar 2 dan Tabel IV memecah hasil menurut jenis gangguan kueri.

Baseline pencocokan awalan B0 mencapai nDCG@10 0,086 pada kueri dengan kesalahan ketik — praktis nol. Perilaku ini konsisten dengan rancangannya: penyaringan awalan membuang seluruh kandidat begitu satu huruf di tengah kata salah, sehingga tidak ada yang tersisa untuk diberi skor. Pada empat jenis degradasi lainnya B0 justru *unggul* atas seluruh sistem, termasuk sistem usulan.




Fig. 3. Sapuan parameter pada 100 kueri pengembangan, korpus 8 entitas. Kiri: bobot jalur kata α ; nilai $\alpha = 0$ (kepingan saja) mencapai 0,728, sedangkan $\alpha = 1$ (kata saja) anjlok ke 0,570. Kanan: panjang kepingan n .

Inilah struktur hasil yang menjelaskan angka agregat: keunggulan sistem usulan terkonsentrasi pada satu jenis kesalahan (typo, 0,668–0,713 vs 0,086), sedangkan pada empat jenis lain ia membayar harga. Rata-rata keduanya menghasilkan selisih kecil yang tidak signifikan.

E. Kinerja per entitas — temuan utama

Tabel V memuat temuan yang paling menjelaskan seluruh naskah ini.

Manfaat sistem usulan **tidak merata dan berbalik tanda**. Pada lima entitas berciri kamus — formulir, obat, konsep, lokasi, penyedia layanan — E3 unggul atau setara, dengan selisih terbesar +0,333 pada formulir dan +0,232 pada obat. Pada tiga entitas yang berisi instans per-pasien — kondisi, hasil laboratorium, dan pasien — E3 kalah dari pencocokan awalan, dengan defisit terbesar –0,242 pada pasien dan –0,180 pada hasil laboratorium.

Pada hasil laboratorium, fusi berbobot memperburuk keadaan secara khusus: E1 mencapai 0,650 sedangkan E3 hanya 0,399. Mekanismenya dapat ditelusuri. Dengan 2.018 dokumen yang hanya memuat 203 judul unik, puluhan dokumen memperoleh skor kosinus yang identik. Fusi berbasis skor mentah (E1) mempertahankan seluruhnya pada tingkat skor yang sama, sedangkan RRF memberi mereka peringkat berurutan $r = 1, 2, \dots, 37$ di dalam entitasnya, sehingga suku $1/(k+r)$ menurun tajam dan sebagian besar dokumen yang sama sahnya terdorong keluar dari sepuluh besar.

F. Sapuan parameter

Seluruh parameter dikunci pada 100 kueri dev sebelum himpunan uji dijalankan. Gambar 3 menyajikan dua sapuan yang paling menentukan.

Sapuan α mencapai maksimum tepat pada $\alpha = 0,20$ (nDCG dev 0,7368), nilai yang sama dengan yang dikunci pada korpus enam entitas — sebuah konfirmasi yang tidak




Fig. 4. nDCG@10 pada 34 kueri konsep pengembangan. Pencarian OpenMRS yang sesungguhnya (B0') mengungguli tiruan pencocokan awalan kami sendiri (B0) sebesar +0,235. Sistem usulan sedikit lebih unggul dari B0', tetapi selisihnya tidak signifikan.

direncanakan. Kedua ujungnya informatif: $\alpha = 1$ (hanya jalur kata) memberi 0,570, sedangkan $\alpha = 0$ (hanya jalur kepingan) memberi 0,728. Jalur kepingan sendirian mengungguli jalur kata sendirian dengan selisih besar.

Sapuan panjang kepingan kembali menunjukkan $n = 3$ sedikit unggul (0,7438) atas $n = 4$ (0,7368), selisih +0,0071, tetapi kali ini uji bootstrap menghasilkan $p = 0,2806$ dengan CI 95% $[-0,0059; +0,0209]$ yang memuat nol. Berbeda dari korpus enam entitas yang memberi $p = 0,0686$ (*borderline*), pada korpus penuh keunggulan $n = 3$ jelas tidak dapat dibedakan dari derau. Nilai $n = 4$ dipertahankan.

Sapuan k pada RRF (5, 10, 20, 60) menghasilkan rentang 0,7340–0,7396 dan sapuan ε (0; 0,05; 0,15; 0,30) menghasilkan 0,7366–0,7387 — keduanya di dalam derau. Nilai 20 dan 0,05 dipertahankan. Tidak ada di antara keempat parameter yang bersumber dari himpunan uji.

G. Perbandingan terhadap pencarian OpenMRS yang sesungguhnya

Tabel VI dan Gambar 4 membandingkan sistem usulan terhadap endpoint OpenMRS yang sesungguhnya pada 34 kueri konsep pengembangan.

Endpoint OpenMRS asli mengungguli tiruan pencocokan awalan kami sendiri sebesar +0,235 nDCG ($p = 0,0006$). Dengan kata lain, baseline yang kami bangun *meremehkan* sistem yang hendak kami bandingkan. Sistem usulan masih di atas OpenMRS asli, tetapi hanya +0,055 dengan $p = 0,269$ — **tidak signifikan**. Yang bertahan adalah keunggulan pada cakupan: B0' meninggalkan 8,8% kueri tanpa hasil, sistem usulan 2,9%.

Dua pemeriksaan validitas dilakukan pada pengukuran ini dan keduanya bersih: tidak satu pun dari 109 hasil yang dikembalikan endpoint berada di luar korpus konsep yang kami indeks, dan tidak satu pun dari 34 kueri menghasilkan urutan berbeda pada dua pemanggilan.

H. Jalur saran ketik

Tabel VII dan Gambar 5 menyajikan hasil evaluasi jalur saran ketik pada 214 kueri, terpisah dari seluruh angka di atas.

TABLE V

NDCG@10 MENURUT ENTITAS SASARAN KUERI (HIMPUNAN UJI, 260 KUERI). KOLOM DIURUTKAN MENURUT SELISIH E3 TERHADAP B0: MANFAAT SISTEM USULAN BERBALIK TANDA ANTARA ENTITAS BERCIRI KAMUS (KIRI) DAN ENTITAS INSTANS PER-PASIENT (KANAN).

Sistem	form	obat	konsep	lokasi	provider	kondisi	hasil lab	pasien
B0	0,667	0,568	0,600	0,727	1,000	0,685	0,579	0,710
B1	0,772	0,614	0,602	0,603	1,000	0,581	0,587	0,391
E1	1,000	0,800	0,723	0,718	1,000	0,741	0,650	0,399
E3	1,000	0,800	0,771	0,785	1,000	0,632	0,399	0,468
$E3 - B0$	+0,333	+0,232	+0,171	+0,058	0,000	-0,053	-0,180	-0,242

TABLE VI

PERBANDINGAN TERHADAP PENCARIAN KONSEP OPENMRS ASLI (34 KUERI KONSEP PENGEMBANGAN). B0' ADALAH ENDPOINT *fuzzy* LUCENE OPENMRS YANG DIPANGGIL LANGSUNG.

Sistem	P@1	nDCG@10	% nol-hasil
B0 (<i>tiruan awalan</i>)	0,588	0,499	29,4
B1 (<i>TF-IDF kata</i>)	0,559	0,527	20,6
B0' (<i>OpenMRS asli</i>)	0,912	0,733	8,8
E1 (+ <i>kepingan</i>)	0,824	0,739	2,9
E3 (<i>usulan</i>)	0,794	0,788	2,9

Uji bootstrap (*seed* = 7, *n* = 34):

E3 vs B0': +0,055, CI [-0,043; +0,153], $p = 0,269$

E3 vs B0 : +0,290, CI [+0,164; +0,417], $p < 0,001$

B0' vs B0: +0,235, CI [+0,119; +0,359], $p = 0,0006$

TABLE VII

AKURASI SARAN KETIK (214 KUERI, KORPUS 8 ENTITAS). TIDAK ADA NDCG UNTUK JALUR INI KARENA IA TIDAK MENYENTUH PERINGKAT.

Jenis	<i>n</i>	hit@1	hit@3	hit@6	MRR@6
persis	52	0,962	1,000	1,000	0,981
typo	66	0,864	0,985	0,985	0,924
trunkasi	46	0,609	0,870	0,913	0,734
trunkasi_pendek	26	0,308	0,462	0,692	0,426
typo_pendek	24	0,125	0,208	0,375	0,192
keseluruhan	214	0,682	0,813	0,869	0,754




Fig. 5. Kiri: akurasi saran menurut jenis degradasi. Kanan: proporsi kueri buntu dan kueri tanpa hasil, sebelum dan sesudah satu klik pada saran teratas.

TABLE VIII

VERIFIKASI SILANG JAVA (LIVE) TERHADAP PYTHON, 100 KUERI DEV, KORPUS 8 ENTITAS. STANDAR EMAS IDENTIK, DIVERIFIKASI MELALUI SHA-256 7ED59A42...CD91EE.

Besaran	Java (live)	Python	Selisih
Dokumen	8.045	8.045	0
Surface form	35.914	35.914	0
Indeks	17	17	0
nDCG@10 mode b0	0,5613	0,5613	0,0000
nDCG@10 mode b1	0,5546	0,5534	0,0012
nDCG@10 mode e1	0,7383	0,7371	0,0012
nDCG@10 mode e3	0,7368	0,7368	0,0000

Kontrol *persis* mencapai hit@3 sempurna, yang menunjukkan metrik dan implementasi bekerja sebagaimana mestinya. Jalur saran kuat pada kesalahan ketik kata utuh (hit@6 0,985) dan memadai pada kata terpotong (0,913), tetapi melemah tajam pada kueri sangat pendek (*typo_pendek* hit@1 0,125). Penyebabnya struktural: Jaccard menghukum kecocokan parsial melalui penyebut gabungan, sehingga prefiks empat sampai enam huruf dari frasa panjang memiliki himpunan gabungan yang besar dan kalah dari kata pendek acak yang kebetulan berbagi dua atau tiga bigram.

Pada metrik interaksi, dari 8,9% kueri yang buntu, satu klik pada saran teratas menyelamatkan 15,8%, menurunkan kebuntuan efektif menjadi 7,5%. Efek yang paling jelas ada pada metrik lain: kueri yang mengembalikan nol dokumen turun dari 3,7% menjadi 0,0%. Kami tidak mengklaim jalur ini meningkatkan mutu peringkat, dan tidak melaporkan nDCG untuknya.

1. Verifikasi silang implementasi dan kinerja modul

Tabel VIII merangkum verifikasi silang antara modul Java yang berjalan di server OpenMRS dan pipeline Python, keduanya pada korpus 8 entitas yang sama.

Korpus cocok persis. Mode b0 dan e3 mereproduksi angka Python tanpa selisih sama sekali. Mode b1 dan e1 berselisih 0,0012 — setara satu kueri yang peringkatnya berbeda. Kedua mode itu memeringkat menurut skor kosinus mentah, dan pada korpus yang memuat puluhan dokumen berjudul identik banyak skor bernilai persis sama, sehingga perbedaan pembulatan floating-point yang sangat kecil dapat membalik urutan pasangan yang seri. Mode e3, yang memeringkat menurut peringkat bilangan bulat alih-alih skor pecahan, kebal terhadap efek itu dan cocok persis. Kami melaporkan selisih ini apa adanya; besarnya jauh di bawah selisih antar-sistem mana pun yang dibahas naskah ini.

Latensi diukur melalui header respons pada permintaan berturut-turut. Setelah 100 permintaan pemanasan, 20 permintaan berikutnya memberi p50 42 ms, p95 50 ms, minimum 39 ms, dan maksimum 63 ms. Angka ini lebih tinggi daripada pada korpus enam entitas (p95 26 ms), sebanding dengan bertambahnya indeks dari 13 menjadi 17 dan surface form dari 29.320 menjadi 35.914.

Determinisme diverifikasi dengan menjalankan pipeline pada proses terpisah; seluruh berkas hasil identik pada tingkat bita, kecuali medan waktu pembangunan indeks. Rangkaian uji unit modul lulus seluruhnya (47 dari 47).

IV. DISCUSSION

A. Jawaban atas rumusan masalah

RQ1. Pada korpus penuh delapan entitas, mesin pencarian terpadu yang diusulkan mencapai nDCG@10 0,670 terhadap 0,631 milik baseline pencocokan awalan. Selisih +0,039 itu **tidak mencapai signifikansi** ($p = 0,079$). Keunggulan yang nyata dan besar berada pada dimensi lain: proporsi kueri tanpa hasil turun dari 15,4% menjadi 0,0%, R@10 naik 0,149, dan MRR naik 0,055.

RQ2. Hanya satu komponen yang menyumbang perolehan besar dan meyakinkan: kepingan karakter, +0,114 nDCG di atas TF-IDF token kata ($p < 0,001$). Fusi peringkat berbobot tidak menyumbang nDCG (-0,011; $p = 0,406$) meski menaikkan P@1 dan MRR. Dua komponen lain merugikan: RRF tanpa bobot (-0,246) dan perluasan kueri otomatis (-0,164).

RQ3. Tidak. Terhadap endpoint pencarian konsep OpenMRS yang sesungguhnya, selisihnya +0,055 dengan $p = 0,269$ — tidak signifikan. Yang bertahan adalah keunggulan cakupan: 2,9% kueri tanpa hasil dibanding 8,8%.

RQ4. Ya. Modul membangun tujuh belas indeks dalam 2,08 detik pada saat mulai dan melayani kueri pada p95 50 ms setelah JVM hangat, tanpa GPU, tanpa server indeks terpisah, dan tanpa sambungan keluar. Korpusnya cocok persis dengan pipeline penelitian, dan dua dari empat mode mereproduksi angkanya tanpa selisih.

B. Temuan utama: manfaatnya bergantung pada sifat entitas

Kontribusi terpenting naskah ini bukan angka agregat, melainkan Tabel V. Manfaat kepingan karakter **berbalik tanda** menurut sifat entitas yang diindeks.

Pada entitas berciri kamus — formulir, obat, konsep, lokasi — setiap dokumen memiliki judul yang unik dan bermakna, sering disertai sinonim dan kode. Di sini kepingan karakter bekerja persis seperti yang diharapkan: ia memulihkan kecocokan yang hancur oleh satu huruf salah, dan sistem usulan unggul +0,171 sampai +0,333.

Pada entitas berisi instans per-pasien — hasil laboratorium, kondisi, pasien — asumsi itu runtuh. Judul berulang lintas ratusan baris: 2.018 hasil laboratorium hanya memuat 203 judul unik. Akibatnya, sebuah kueri tidak lagi memiliki satu jawaban benar melainkan puluhan yang sama sahnya, dan tugasnya berubah dari *menemukan entri yang tepat* menjadi *milih instans yang tepat* — tugas yang tidak dapat diselesaikan oleh kecocokan teks, karena seluruh kandidat memiliki teks

yang identik. Pada tugas semacam itu pencocokan awalan yang mengembalikan sedikit hasil eksak justru lebih menguntungkan menurut nDCG@10 daripada sistem yang mengembalikan banyak kandidat serupa.

Fusi peringkat berbobot memperburuk keadaan pada kasus ini secara khusus dan dapat dijelaskan mekanismenya: RRF mengubah skor identik menjadi peringkat berurutan, dan suku $1/(k+r)$ kemudian mendorong sebagian besar kandidat yang sama sahnya keluar dari sepuluh besar. Itu sebabnya E3 (0,399) jauh di bawah E1 (0,650) pada hasil laboratorium.

Implikasi praktisnya langsung: pada instalasi OpenMRS, jalur kepingan karakter sebaiknya diterapkan pada entitas kamus, sementara entitas instans per-pasien lebih baik dilayani pencarian berbasis awalan yang digabungkan dengan penyaring terstruktur (tanggal, pasien, rentang nilai). Merapikan keduanya di bawah satu fungsi peringkat, seperti yang dilakukan sistem ini, membayar harga yang terukur.

C. Mengapa angka ini jauh lebih kecil daripada versi enam entitas

Versi awal penelitian ini mengevaluasi enam entitas dan melaporkan E3 unggul +0,187 nDCG atas B0 dengan $p < 0,001$. Pada korpus penuh delapan entitas angka yang sama menjadi +0,039 dengan $p = 0,079$. Penyusutan itu bukan akibat perubahan algoritma — parameternya identik, kodenya sama — melainkan akibat masuknya dua entitas yang sifatnya berbeda secara mendasar.

Kami menilai versi delapan entitas sebagai versi yang benar, dengan alasan sederhana: itulah cakupan yang benar-benar diindeks oleh modul yang dipasang pengguna. Melaporkan angka enam entitas berarti melaporkan sistem yang tidak dijalankan siapa pun. Bahwa angka yang benar jauh lebih kecil adalah hasil, bukan alasan untuk kembali ke cakupan yang lebih menguntungkan.

D. Apa yang tetap bertahan

Tiga klaim bertahan dengan kuat dan tidak bergantung pada cakupan korpus.

Pertama, penghapusan jalan buntu. Baseline pencocokan awalan meninggalkan 15,4% kueri tanpa hasil sama sekali; seluruh varian berkepingan karakter menurunkannya ke nol. Dalam konteks klinis, layar kosong adalah mode kegagalan yang berbeda secara kualitatif dari hasil yang buruk — ia menghentikan alur kerja, bukan memperlambatnya [6], [32]. Ukuran ini tidak tertangkap oleh nDCG@10, dan justru di sinilah letak nilai praktis metode ini.

Kedua, ketahanan terhadap kesalahan ketik. Pada kueri bertipe typo, pencocokan awalan mencapai 0,086 sementara sistem hibrida mencapai 0,668–0,713. Perbedaan hampir delapan kali lipat itu adalah manifestasi konkret dari sifat kepingan karakter yang sudah dikenal pada kepustakaan pencocokan string aproksimatif [14], [15] dan perolehan lintas-bahasa [16].

Ketiga, pentingnya pembobotan pada fusi antar-entitas. RRF tanpa bobot menurunkan nDCG@10 sebesar 0,246 dan meruntuhkan P@1 ke 0,108. Pembobotan berbasis indeks global mengembalikan P@1 ke 0,681. Temuan ini menguat, bukan melemah, pada korpus yang lebih heterogen — sejalan

dengan analisis fungsi fusi yang menemukan bahwa fusi berbasis peringkat memerlukan pembobotan ketika daftar sumber memiliki karakteristik yang sangat berbeda [24], [25].

E. Pelajaran metodologis: baseline dan korpus yang setia

Dua kekeliruan metodologis ditemukan dalam penelitian ini sendiri, dan keduanya bergerak ke arah yang sama — membesarkan klaim.

Baseline yang tidak setia. Kami membangun B0 sebagai tiruan “pencarian bawaan OpenMRS”. Ketika endpoint yang sesungguhnya akhirnya dipanggil langsung, ia mengalahkan tiruan kami sendiri sebesar +0,235 nDCG. Satu asumsi yang tidak diuji — bahwa pencarian OpenMRS bekerja dengan pencocokan awalan, padahal pencarian konsepnya memakai fuzzy berbasis Lucene — melibatkan besaran klaim beberapa kali.

Korpus evaluasi yang tidak setia. Pipeline penelitian mengindeks enam entitas sementara modul yang dipasang mengindeks delapan. Selama endpoint REST instalasi uji mengalami gangguan, ketidakcocokan itu tidak terlihat sama sekali; ia baru terungkap ketika endpoint pulih dan angka evaluasi live dapat dibandingkan dengan angka pipeline.

Pelajarannya berlaku umum untuk penelitian yang mengusulkan perbaikan atas sistem yang sudah berjalan: ukurlah terhadap sistem itu sendiri, pada cakupan data yang sama dengan yang benar-benar dijalankan. Rekonstruksi dari dokumentasi dan subhimpunan data yang nyaman keduanya cenderung menguntungkan sistem yang diusulkan.

Kami juga mencatat bahwa penelitian ini pernah mencemari himpunan ujinya sendiri melalui sapuan parameter yang keliru dijalankan pada bagian uji. Seluruh angka sapuan dijalankan ulang pada himpunan pengembangan dan skrip lama diarsipkan.

F. Perbandingan dengan kepustakaan

Sistem pencarian RME yang matang seperti EMERSE [7] dan Doc’EDS [38] berfokus pada perolehan dokumen naratif dan memanfaatkan mesin indeks penuh, sementara pendekatan rekomendasi kueri berbasis semantik [39] menuntut sumber daya terminologi tambahan. Penelitian mengenai koreksi ejaan pada domain kesehatan umumnya memperlakukan koreksi sebagai tugas tersendiri dengan leksikon dan model bahasa [8]–[10]. Kontribusi naskah ini terletak pada sisi yang berbeda: toleransi salah ketik dicapai *di dalam* fungsi peringkat, tanpa leksikon koreksi, tanpa model bahasa, dan tanpa mesin indeks eksternal — pilihan yang ditentukan oleh batasan penerapan.

Dibandingkan pemeringkat neural [34]–[36], hasil kami jelas bukan kompetisi mutu absolut; kami tidak menguji sistem neural dan tidak mengklaim keunggulan atasnya. Klaim kami kini bahkan lebih sempit daripada yang semula direncanakan: pada kelas fasilitas yang menjadi sasaran OpenMRS, kerugian akibat salah ketik dapat dipulihkan tanpa akselerator dan tanpa konektivitas, dengan biaya latensi puluhan milidetik — tetapi perolehan itu terkonsentrasi pada entitas berciri kamus, dan tidak berlaku merata.

G. Keterbatasan

Kueri sintetis. Kueri dibangkitkan dengan menerapkan lima jenis degradasi pada judul dokumen, bukan diambil dari log klinisi. Model degradasi ini didasarkan pada taksonomi kesalahan yang mapan [11], [12], tetapi distribusi jenis kesalahan pada kueri nyata hampir pasti berbeda. Karena sistem usulan unggul hanya pada satu jenis degradasi dari lima, hasil agregat sangat peka terhadap asumsi distribusi ini — kelemahan yang lebih menonjol pada korpus delapan entitas daripada sebelumnya.

Dua model relevansi dalam satu metrik. Standar emas memakai tautan struktural untuk enam entitas dan kesamaan judul untuk dua entitas lainnya. Menggabungkan keduanya dalam satu angka nDCG melemahkan ketertafsirannya. Kami melaporkan pemecahan per entitas justru karena alasan itu.

Kueri pasien dan hasil laboratorium tidak realistis. Pada praktik nyata, pencarian pasien dan hasil laboratorium hampir selalu disertai penyaring terstruktur (identitas, tanggal, jenis pemeriksaan). Eksperimen ini memperlakukannya sebagai pencarian teks bebas murni, yang menyudutkan seluruh sistem — termasuk baseline — pada tugas yang tidak sepenuhnya mewakili penggunaan sebenarnya.

Cakupan B0’ sempit. Baseline yang setia hanya dapat diukur pada 34 kueri konsep pengembangan, karena OpenMRS tidak menyediakan pencarian tahan salah ketik untuk tujuh entitas lainnya. Dengan $n = 34$, daya ujinya rendah; ketiadaan signifikansi pada perbandingan E3 vs B0’ tidak boleh dibaca sebagai bukti ketiadaan perbedaan.

Skala korpus. Instalasi yang diuji berisi 4.249 konsep, sedangkan kamus CIEL penuh berisi sekitar 50.000 konsep. Indeks kepingan berukuran tiga sampai lima kali indeks kata.

Indeks statis. Indeks dibangun satu kali saat modul mulai. Pasien, hasil laboratorium, atau konsep baru tidak masuk indeks sampai modul dijalankan ulang — keterbatasan yang dapat diterima untuk kamus terminologi, tetapi serius untuk data pasien pada penggunaan produksi.

Validasi klinis belum dilakukan. Seluruh pengukuran bersifat berbasis korpus. Tidak ada studi pengguna dan tidak ada bukti bahwa perubahan nDCG diterjemahkan menjadi manfaat klinis.

H. Pekerjaan lanjutan

Temuan utama naskah ini langsung menunjuk arah berikutnya. *Pertama*, memisahkan strategi peringkat menurut sifat entitas — kepingan karakter untuk entitas kamus, pencocokan awalan berpenyaring terstruktur untuk entitas instans — lalu mengukur apakah pemisahan itu mengungguli fungsi peringkat tunggal. *Kedua*, memperlakukan kelompok dokumen berjudul sama sebagai satu satuan peringkat dengan daftar instans di dalamnya, alih-alih sebagai puluhan dokumen yang bersaing. *Ketiga*, studi pengguna dengan klinisi, karena metrik berbasis korpus jelas tidak menangkap nilai penghapusan layar kosong. *Keempat*, evaluasi pada kamus CIEL penuh untuk mengukur perilaku memori dan latensi pada skala produksi.

I. Simpulan

Penelitian ini membangun dan mengevaluasi mesin pencarian terpadu lintas-entitas yang tahan salah ketik untuk OpenMRS, seluruhnya dari teknik perolehan informasi leksikal klasik, pada korpus yang cakupannya sama persis dengan modul yang dipasang.

Hasilnya berlapis dan harus dinyatakan lengkap. Pada 260 kueri uji yang dijalankan satu kali, sistem mencapai $nDCG@10$ 0,670 terhadap 0,631 milik baseline pencocokan awalan — selisih yang **tidak signifikan** ($p = 0,079$). Terhadap pencarian konsep OpenMRS yang sesungguhnya, selisihnya juga tidak signifikan ($p = 0,269$). Klaim peningkatan mutu peringkat, dengan demikian, tidak dapat dipertahankan pada korpus penuh.

Yang dapat dipertahankan adalah tiga hal lain: kueri tanpa hasil hilang sepenuhnya (15,4% menjadi 0,0%), ketahanan terhadap kesalahan ketik meningkat hampir delapan kali lipat (0,086 menjadi 0,713), dan implementasinya terbukti ringan — tujuh belas indeks dalam 2,08 detik, p95 50 ms, tanpa GPU dan tanpa sambungan keluar.

Temuan yang paling berguna bagi peneliti berikutnya adalah bahwa manfaat kepingan karakter *bergantung pada sifat entitas*: besar pada data berciri kamus, negatif pada data instans per-pasien yang judulnya berulang. Ketergantungan itu tidak terlihat selama korpus evaluasi lebih sempit daripada korpus yang sesungguhnya dipasang — dan itulah alasan paling kuat untuk menyamakan keduanya sejak awal.

UCAPAN TERIMA KASIH

Penulis berterima kasih kepada komunitas OpenMRS atas ketersediaan kode sumber, sebaran Reference Application, dan demo data yang menjadi dasar seluruh eksperimen dalam penelitian ini.

- [1] B. W. Mamlin, P. G. Biondich, B. A. Wolfe, H. Fraser, D. Jazayeri, C. Allen, J. Miranda, and W. M. Tierney, "Cooking up an open source EMR for developing countries: OpenMRS — a recipe for successful collaboration," *AMIA Annu. Symp. Proc.*, vol. 2006, pp. 529–533, 2006. PMID: 17238397.
- [2] C. J. Seebregts, B. W. Mamlin, P. G. Biondich, H. S. F. Fraser, B. A. Wolfe, D. Jazayeri, C. Allen, J. Miranda, E. Baker, N. Musinguzi, D. Kanyiwa, S. Fourie, N. Lesh, C. Kanter, C. J. Yiannoutsos, and C. Bailey, "The OpenMRS Implementers Network," *Int. J. Med. Inform.*, vol. 78, no. 11, pp. 711–720, Nov. 2009, doi: 10.1016/j.ijmedinf.2008.09.005.
- [3] H. S. F. Fraser, P. Biondich, D. Moodley, S. Choi, B. W. Mamlin, and P. Szolovits, "Implementing electronic medical record systems in developing countries," *Inform. Prim. Care*, vol. 13, no. 2, pp. 83–95, 2005, doi: 10.14236/jhi.v13i2.585.
- [4] N. Muinga, S. Magare, J. Monda, O. Kamau, S. Houston, H. Fraser, N. Powell, M. English, and C. Paton, "Implementing an open source electronic health record system in Kenyan health care facilities: Case study," *JMIR Med. Inform.*, vol. 6, no. 2, p. e22, Apr. 2018, doi: 10.2196/medinform.8403.
- [5] T. Lewis, C. Synowiec, G. Lagomarsino, and J. Schweitzer, "E-health in low- and middle-income countries: findings from the Center for Health Market Innovations," *Bull. World Health Organ.*, vol. 90, no. 5, pp. 332–340, May 2012, doi: 10.2471/BLT.11.099820.
- [6] K. Natarajan, D. Stein, S. Jain, and N. Elhadad, "An analysis of clinical queries in an electronic health record search utility," *Int. J. Med. Inform.*, vol. 79, no. 7, pp. 515–522, Jul. 2010, doi: 10.1016/j.ijmedinf.2010.03.004.
- [7] D. A. Hanauer, Q. Mei, J. Law, R. Khanna, and K. Zheng, "Supporting information retrieval from electronic health records: A report of University of Michigan's nine-year experience in developing and using the Electronic Medical Record Search Engine (EMERSE)," *J. Biomed. Inform.*, vol. 55, pp. 290–300, Jun. 2015, doi: 10.1016/j.jbi.2015.05.003.
- [8] K. H. Lai, M. Topaz, F. R. Goss, and L. Zhou, "Automated misspelling detection and correction in clinical free-text records," *J. Biomed. Inform.*, vol. 55, pp. 188–195, Jun. 2015, doi: 10.1016/j.jbi.2015.04.008.
- [9] J. Crowell, Q. Zeng, L. Ngo, and E.-M. Lacroix, "A frequency-based technique to improve the spelling suggestion rank in medical queries," *J. Am. Med. Inform. Assoc.*, vol. 11, no. 3, pp. 179–185, May 2004, doi: 10.1197/jamia.M1474.
- [10] H. Kilicoglu, M. Fiszman, K. Roberts, and D. Demner-Fushman, "An ensemble method for spelling correction in consumer health questions," *AMIA Annu. Symp. Proc.*, vol. 2015, pp. 727–736, 2015. PMID: 26958208.
- [11] K. Kukich, "Techniques for automatically correcting words in text," *ACM Comput. Surv.*, vol. 24, no. 4, pp. 377–439, Dec. 1992, doi: 10.1145/146370.146380.
- [12] F. J. Damerau, "A technique for computer detection and correction of spelling errors," *Commun. ACM*, vol. 7, no. 3, pp. 171–176, Mar. 1964, doi: 10.1145/363958.363994.
- [13] R. A. Wagner and M. J. Fischer, "The string-to-string correction problem," *J. ACM*, vol. 21, no. 1, pp. 168–173, Jan. 1974, doi: 10.1145/321796.321811.
- [14] E. Ukkonen, "Approximate string-matching with q -grams and maximal matches," *Theor. Comput. Sci.*, vol. 92, no. 1, pp. 191–211, Jan. 1992, doi: 10.1016/0304-3975(92)90143-4.
- [15] G. Kondrak, "N-gram similarity and distance," in *String Processing and Information Retrieval (SPIRE 2005)*, Lecture Notes in Computer Science, vol. 3772, Berlin, Germany: Springer, 2005, pp. 115–126, doi: 10.1007/11575832_13.
- [16] P. McNamee and J. Mayfield, "Character n -gram tokenization for European language text retrieval," *Inf. Retr.*, vol. 7, no. 1–2, pp. 73–97, Jan. 2004, doi: 10.1023/B:INRT.0000009441.78971.be.
- [17] L. Boytsov, "Indexing methods for approximate dictionary searching: Comparative analysis," *ACM J. Exp. Algorithmics*, vol. 16, art. 1.1, May 2011, doi: 10.1145/1963190.1963191.
- [18] G. Salton, A. Wong, and C. S. Yang, "A vector space model for automatic indexing," *Commun. ACM*, vol. 18, no. 11, pp. 613–620, Nov. 1975, doi: 10.1145/361219.361220.
- [19] G. Salton and C. Buckley, "Term-weighting approaches in automatic text retrieval," *Inf. Process. Manage.*, vol. 24, no. 5, pp. 513–523, 1988, doi: 10.1016/0306-4573(88)90021-0.
- [20] K. Spärck Jones, "A statistical interpretation of term specificity and its application in retrieval," *J. Documentation*, vol. 28, no. 1, pp. 11–21, Jan. 1972, doi: 10.1108/eb026526.
- [21] S. Robertson, "Understanding inverse document frequency: on theoretical arguments for IDF," *J. Documentation*, vol. 60, no. 5, pp. 503–520, Oct. 2004, doi: 10.1108/00220410410560582.
- [22] S. Robertson and H. Zaragoza, "The probabilistic relevance framework: BM25 and beyond," *Found. Trends Inf. Retr.*, vol. 3, no. 4, pp. 333–389, 2009, doi: 10.1561/15000000019.
- [23] J. Zobel and A. Moffat, "Exploring the similarity space," *ACM SIGIR Forum*, vol. 32, no. 1, pp. 18–34, Apr. 1998, doi: 10.1145/281250.281256.
- [24] G. V. Cormack, C. L. A. Clarke, and S. Büttcher, "Reciprocal rank fusion outperforms Condorcet and individual rank learning methods," in *Proc. 32nd Int. ACM SIGIR Conf. Research and Development in Information Retrieval*, Boston, MA, USA, 2009, pp. 758–759, doi: 10.1145/1571941.1572114.
- [25] S. Bruch, S. Gai, and A. Ingber, "An analysis of fusion functions for hybrid retrieval," *ACM Trans. Inf. Syst.*, vol. 42, no. 1, art. 20, pp. 1–35, Jan. 2024, doi: 10.1145/3596512.
- [26] I. Ruthven, "Re-examining the potential effectiveness of interactive query expansion," in *Proc. 26th Annu. Int. ACM SIGIR Conf. Research and Development in Information Retrieval*, Toronto, ON, Canada, 2003, pp. 213–220, doi: 10.1145/860435.860475.
- [27] P. Jaccard, "The distribution of the flora in the alpine zone," *New Phytologist*, vol. 11, no. 2, pp. 37–50, Feb. 1912, doi: 10.1111/j.1469-8137.1912.tb05611.x.
- [28] K. Järvelin and J. Kekäläinen, "Cumulated gain-based evaluation of IR techniques," *ACM Trans. Inf. Syst.*, vol. 20, no. 4, pp. 422–446, Oct. 2002, doi: 10.1145/582415.582418.
- [29] B. Efron, "Bootstrap methods: Another look at the jackknife," *Ann. Statist.*, vol. 7, no. 1, pp. 1–26, Jan. 1979, doi: 10.1214/aos/1176344552.

- [30] M. D. Smucker, J. Allan, and B. Carterette, "A comparison of statistical significance tests for information retrieval evaluation," in *Proc. 16th ACM Conf. Information and Knowledge Management*, Lisbon, Portugal, 2007, pp. 623–632, doi: 10.1145/1321440.1321528.
- [31] T. Sakai, "Evaluating evaluation metrics based on the bootstrap," in *Proc. 29th Annu. Int. ACM SIGIR Conf. Research and Development in Information Retrieval*, Seattle, WA, USA, 2006, pp. 525–532, doi: 10.1145/1148170.1148261.
- [32] W. Hersh, *Information Retrieval: A Biomedical and Health Perspective*, 4th ed. Cham, Switzerland: Springer, 2020, doi: 10.1007/978-3-030-47686-1.
- [33] C. J. McDonald, S. M. Huff, J. G. Suico, G. Hill, D. Leavelle, R. Aller, A. Forrey, K. Mercer, G. DeMoor, J. Hook, W. Williams, J. Case, and P. Maloney, "LOINC, a universal standard for identifying laboratory observations: A 5-year update," *Clin. Chem.*, vol. 49, no. 4, pp. 624–633, Apr. 2003, doi: 10.1373/49.4.624.
- [34] J. Lin, R. Nogueira, and A. Yates, *Pretrained Transformers for Text Ranking: BERT and Beyond*, Synthesis Lectures on Human Language Technologies. Cham, Switzerland: Springer, 2022, doi: 10.1007/978-3-031-02181-7.
- [35] O. Khattab and M. Zaharia, "ColBERT: Efficient and effective passage search via contextualized late interaction over BERT," in *Proc. 43rd Int. ACM SIGIR Conf. Research and Development in Information Retrieval*, 2020, pp. 39–48, doi: 10.1145/3397271.3401075.
- [36] T. Formal, B. Piwowarski, and S. Clinchant, "SPLADE: Sparse lexical and expansion model for first stage ranking," in *Proc. 44th Int. ACM SIGIR Conf. Research and Development in Information Retrieval*, 2021, pp. 2288–2292, doi: 10.1145/3404835.3463098.
- [37] E. Strubell, A. Ganesh, and A. McCallum, "Energy and policy considerations for deep learning in NLP," in *Proc. 57th Annu. Meeting Assoc. Computational Linguistics*, Florence, Italy, 2019, pp. 3645–3650, doi: 10.18653/v1/P19-1355.
- [38] T. Pressat-Laffouilhère, P. Balayé, B. Dahamna, R. Lelong, K. Billey, S. J. Darmoni, and J. Grosjean, "Evaluation of Doc'EDS: a French semantic search tool to query health documents from a clinical data warehouse," *BMC Med. Inform. Decis. Mak.*, vol. 22, art. 34, Feb. 2022, doi: 10.1186/s12911-022-01762-4.
- [39] D. T. Y. Wu, D. Hanauer, P. Murdock, V. G. V. Vydiswaran, Q. Mei, and K. Zheng, "Developing a semantically based query recommendation for an electronic medical record search engine: Query log analysis and design implications," *JMIR Form. Res.*, vol. 7, p. e45376, 2023, doi: 10.2196/45376.

LAMPIRAN

Pencarian Terpadu Tahan Salah Ketik pada OpenMRS

Lampiran ini memuat seluruh tautan ke berkas pendukung penelitian: kode sumber, data, tutorial menjalankan, panduan pengguna, dan bahan presentasi. Seluruh berkas yang dapat dipublikasikan berada pada satu repositori GitHub; berkas yang berukuran besar atau tidak cocok disimpan di repositori kode (rekaman demo, kumpulan slide) berada pada Google Drive dan tautannya dicantumkan di Lampiran B.

Lampiran A Repositori Kode Sumber dan Berkas Pendukung

Repositori utama: <https://github.com/stephenprasetyachrisman/openmrs-tfidf-ngram>

Seluruh butir pada tabel berikut berada di dalam repositori tersebut. Kolom “Lokasi” adalah lintasan relatif terhadap akar repositori.

Butir lampiran	Lokasi di repositori	Keterangan
Kode sumber modul OpenMRS	backend/ openmrs-module- tfidf-search/	Modul Java (.omod). Berisi seluruh algoritma K1–K6: normalisasi, tokenisasi kata dan kepingan karakter, pembobotan <i>l_{tc}</i> , fusi tingkat satu, <i>Weighted RRF</i> , baseline B0, jalur saran ketik, serta dua endpoint REST. Dilengkapi 47 uji unit.
Kode sumber antarmuka	frontend/ esm-unified-search/	Microfrontend (ESM) untuk OpenMRS Reference Application 3: halaman “Pencarian Terpadu”, halaman “Perbandingan Pencarian”, dan panel evaluasi.
Kode eksperimen	riset/	Implementasi rujukan Python untuk seluruh angka pada naskah: <code>eksperimen2.py</code> (sistem B0–E4, himpunan uji), <code>eksperimen3_baseline_asli.py</code> (baseline B0'), <code>eksperimen_k2.py</code> (jalur saran ketik), <code>sapuan_dev.py</code> dan <code>sapuan_alpha_dev.py</code> (sapuan parameter).
Dataset / basis data	riset/data/*.jsonl riset/ekspor/*.sql	Korpus hasil ekspor dari basis data OpenMRS dalam format JSON Lines (konsep, obat, pasien, lain, hasillab, kondisi), beserta kueri SQL yang dipakai untuk mengekspornya sehingga dapat dibangkitkan ulang dari instalasi OpenMRS mana pun.
Berkas hasil eksperimen	riset/hasil4/ ...riset/hasil6/	Keluaran mentah tiap eksperimen (<code>hasil.json</code> , <code>per_query.json</code> , <code>ringkasan.csv</code> , <code>laporan.md</code>). Pemetaan berkas ke tabel dan gambar naskah ada pada Lampiran F.
Tutorial menjalankan kode	README.md	Panduan lengkap dari nol: prasyarat, penyalakan stack Docker, pembangunan modul, pemasangan, verifikasi, sampai halaman terbuka di peramban. Disertai bagian penanganan galat yang sering muncul.
Panduan reproduksi hasil	docs/reproduksi.md	Sembilan langkah untuk mengulang seluruh angka penelitian, masing-masing dengan kriteria “cara tahu berhasil” yang dapat diperiksa.
Panduan pengguna	docs/panduan-pengguna.md	Cara memakai halaman Pencarian Terpadu, halaman Perbandingan Pencarian, kotak saran ketik, dan panel evaluasi dari sudut pandang pengguna akhir.

bersambung ke halaman berikutnya

Lampiran A, lanjutan

Butir lampiran	Lokasi di repositori	Keterangan
Spesifikasi algoritma	docs/algoritma.md	Spesifikasi K1–K6, baseline B0, dan jalur saran ketik K2, cukup rinci untuk diimplementasikan ulang tanpa menebak.
Kontrak data	docs/kontrak-data.md	Bentuk dokumen virtual yang menyatukan delapan entitas OpenMRS; wajib diikuti persis bila menambahkan entitas baru.
Catatan keputusan	docs/keputusan.md	Seluruh keputusan rancangan dan temuan penelitian secara kronologis, termasuk kekeliruan yang ditemukan dan cara memperbaikinya. Rujukan utama untuk pengembangan lanjutan.
Fakta lingkungan	docs/lingkungan.md	Versi platform terverifikasi, alamat, kredensial basis data, jumlah baris tabel, dan jebakan lingkungan yang sudah terdokumentasi.
Aturan proyek	CLAUDE.md	Sepuluh aturan yang mengikat seluruh perubahan kode dan dokumen, termasuk aturan determinisme dan larangan mengubah angka hasil.
Proposal penelitian	docs/proposal.html	Proposal lengkap beserta <i>mockup</i> interaktif dan contoh perhitungan.
Naskah artikel ini	article/	Sumber L ^A T _E X naskah, skrip pembangun gambar, dan berkas hasil kompilasi.

Lampiran B Tautan Berkas Pendukung Eksternal

Berkas berikut berada di Google Drive karena ukurannya tidak sesuai untuk disimpan pada repositori kode.

Berkas	Tautan
Kumpulan PPT Progress Seluruh slide laporan kemajuan penelitian, berurutan menurut tanggal.	<i>[tempelkan tautan Google Drive di sini]</i>
Demo Aplikasi Rekaman layar modul yang berjalan: kueri gagal pada kotak pencarian bawaan, kueri yang sama berhasil pada sistem usulan.	<i>[tempelkan tautan Google Drive di sini]</i>

Catatan bagi penulis: kedua tautan di atas diisi pada blok TAUTAN di kepala berkas `article/lampiran.tex` (makro `\tautanPPT` dan `\tautanDemo`). Tidak perlu mengubah tabel ini.

Lampiran C Peta Isi Repositori

```
openmrs-tfidf-ngram/
|
+-- README.md          tutorial lengkap menjalankan dari nol
+-- CLAUDE.md          aturan proyek yang mengikat
|
+-- backend/openmrs-module-tfidf-search/
|   +-- api/           algoritma inti + 47 uji unit
|   |   +-- src/main/java/org/openmrs/module/unifiedsearch/
```


Lampiran D Ringkasan Langkah Menjalankan

Ringkasan ini memuat perintah intinya saja. Penjelasan lengkap setiap langkah, termasuk cara memastikan langkah itu berhasil dan penanganan galat yang sering muncul, ada pada `README.md` di akar repositori.

Prasyarat: Docker Desktop, Git, JDK 17, Node.js 20+, Python 3.9+, dan PowerShell (Windows). Rincian versi terverifikasi ada pada `docs/lingkungan.md`.

No.	Langkah	Perintah
1	Klon repositori penelitian	<code>git clone https://github.com/stephenprasetyachrismaawan/openmrs-tfidf-ngram.git</code>
2	Klon stack Docker OpenMRS sejajar dengan repositori penelitian	<code>git clone https://github.com/openmrs/openmrs-distro-referenceapplication.git</code>
3	Nyalakan stack (tanpa <code>-p</code>)	<code>cd openmrs-distro-referenceapplication</code> <code>docker compose up -d</code>
4	Tunggu empat kontainer sehat	<code>docker ps</code>
5	Bangun dan pasang modul backend	<code>.\scripts\pasang-modul.ps1</code>
6	Bangun dan pasang antarmuka ESM	<code>.\scripts\pasang-esm.ps1</code>
7	Verifikasi menyeluruh	<code>.\scripts\verify-openmrs.ps1</code>
8	Buka di peramban	<code>http://127.0.0.1/openmrs/spa/unified-search</code>

Peringatan lingkungan. Seluruh alamat memakai `http://127.0.0.1`, *bukan* `localhost`. Pada sebagian mesin Windows, `localhost` teresolusi ke IPv6 `::1` yang mungkin dikuasai server lain, sehingga seluruh lintasan `/openmrs/...` mengembalikan 404. Bila muncul halaman bawaan Apache, yang salah adalah alamatnya, bukan modulnya.

Kredensial demo bawaan: `admin / Admin123`.

Lampiran E Antarmuka REST Modul

Basis alamat: `http://127.0.0.1/openmrs/ws/rest/v1/unifiedsearch`

Endpoint	Parameter	Keterangan
GET <code>/unifiedsearch</code>	<code>q</code> (wajib) <code>mode = b0 b1 e1 e3</code> (bawaan <code>e3</code>) <code>limit</code> (bawaan 10) <code>entitas</code> (opsional)	Pencarian terpadu. Parameter <code>mode</code> memilih sistem, sehingga kontribusi tiap komponen dapat diukur ulang kapan saja tanpa mengubah kode.
GET <code>/unifiedsearch/saran</code>	<code>q</code> (wajib) <code>limit</code> (bawaan 6)	Saran ketik “Maksud Anda” berbasis Jaccard bigram. Jalur terpisah; tidak menyentuh peringkat. Hasil berjenis pasien, hasil laboratorium, dan kondisi disaring menurut privilege <code>View Patients</code> pemanggil.
GET <code>/unifiedsearch/eval</code>	<code>mode</code> (bawaan <code>e3</code>)	Menjalankan evaluasi atas 100 kueri pengembangan dan mengembalikan <code>P@1</code> , <code>P@5</code> , <code>R@10</code> , <code>MRR</code> , <code>MAP</code> , <code>nDCG@10</code> , serta proporsi kueri tanpa hasil. Jawaban menyertakan <code>gold_sha256</code> agar standar emas yang dipakai dapat dicocokkan.

Setiap jawaban menyertakan tajuk `X-Unifiedsearch-Waktu-Ms` berisi waktu pemrosesan. Waktu sengaja ditempatkan pada tajuk, bukan pada badan JSON, agar dua panggilan yang sama menghasilkan badan jawaban yang identik pada tingkat bita — syarat pengujian determinisme.

Contoh pemanggilan:

```
curl -u admin:Admin123 \
  "http://127.0.0.1/openmrs/ws/rest/v1/unifiedsearch?q=diabete%20melitus&mode=e3"
```

Lampiran F Pemetaan Berkas Hasil ke Tabel dan Gambar Naskah

Tidak ada angka pada naskah ini yang diketik ulang secara manual ke dalam gambar. Skrip `article/gambar/buat_gambar.py` membaca berkas hasil di bawah dan membangun ulang seluruh gambar; bila eksperimen dijalankan ulang dan angkanya berubah, gambarnya ikut berubah.

Bagian naskah	Berkas sumber	Cakupan
Tabel II, III, IV, V; Gambar 1, 2	<code>riset/hasil6/hasil.json</code>	260 kueri uji, korpus 8 entitas, sekali jalan, parameter terkunci
Gambar 3	<code>riset/hasil6/sapuan_dev.json</code>	Sapuan $\alpha, n, k, \varepsilon$ pada 100 kueri pengembangan
Tabel VI; Gambar 4	<code>riset/hasil4/hasil.json</code>	34 kueri konsep, baseline B0' (endpoint OpenMRS asli)
Tabel VII; Gambar 5	<code>riset/hasil5/hasil.json</code>	214 kueri, jalur saran ketik, korpus 8 entitas
Tabel VIII, angka latensi dan determinisme	<code>docs/keputusan.md</code> bagian C1–C4, F1–F2	Verifikasi silang Java–Python dan pengukuran kinerja modul

Cara membangkitkan ulang seluruh angka: jalankan `python riset/eksperimen2.py` (himpunan uji), `python riset/eksperimen3_baseline_asli.py` (baseline B0', perlu stack Docker berjalan), dan `python riset/eksperimen_k2.py` (jalur saran ketik), lalu `python article/gambar/buat_gambar.py` untuk membangun ulang gambar. Seluruh skrip deterministik: benih acak dipatok, pengurutan memakai kunci majemuk, dan iterasi himpunan selalu diurutkan lebih dahulu, sehingga dua proses terpisah menghasilkan berkas yang identik pada tingkat bita.