

**PENGEMBANGAN SISTEM Pencarian Informasi pada
OPENMRS
Menggunakan Semantic Query Routing dan TF-IDF**



Anggota Kelompok:

STEPHEN PRASETYA CHRISMAWAN (25/563032/PPA/07093)

M. SYARIF HIDAYATULLAH (25/567018/PPA/07143)

SAMPURNO AJI (25/568826/PPA/07155)

REZA PURWANTARA FIRDAUS (25/565168/PPA/07125)

**PROGRAM MAGISTER ILMU KOMPUTER
DEPARTEMEN ILMU KOMPUTER DAN ELEKTRONIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA**

DAFTAR ISI

DAFTAR TABEL	iv
--------------	----

DAFTAR GAMBAR	v
---------------	---

BAB I: PENDAHULUAN	1
--------------------	---

1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Batasan Penelitian	3
1.4 Tujuan Penelitian	4
1.5 Manfaat Penelitian	4

BAB II: TINJAUAN PUSTAKA	6
--------------------------	---

2.1 Electronic Medical Record dan Kebutuhan Temu Kembali Informasi	6
2.2 OpenMRS	6
2.3 Information Retrieval pada Rekam Medis Elektronik	7
2.4 TF-IDF dan Model Ruang Vektor	7
2.5 Query Routing dan Pencarian Multi-Domain	8
2.6 Pemrosesan Teks dan Pengayaan Terminologi Medis	8
2.7 Demo Data Resmi OpenMRS sebagai Dataset Penelitian	8
2.8 Interoperabilitas dan Akses Data OpenMRS	9
2.9 Evaluasi Sistem Temu Kembali	9
2.10 Perkembangan Pencarian Semantik dan Posisi Penelitian	10

BAB III: METODOLOGI PENELITIAN	11
--------------------------------	----

3.1 Alur Penelitian	11
3.2 Pendekatan Umum Penelitian	14
3.3 Identifikasi Permasalahan	14
3.4 Studi Literatur	15
3.5 Dataset Penelitian	15
3.6 Inventarisasi Entitas dan Domain Pencarian	16
3.7 Penyiapan Demo Data OpenMRS	16

3.8	Verifikasi Demo Data	17
3.9	Domain Pencarian	17
3.10	Pembentukan Dokumen Pencarian	17
3.11	Text Preprocessing	19
3.12	Metode TF-IDF	19
3.13	Cosine Similarity	20
3.14	Metode General Search	20
3.14.1	Pembentukan Profil Domain	20
3.14.2	Perhitungan Skor Routing	21
3.14.3	Pemilihan Domain	21
3.14.4	Retrieval pada Domain Terpilih	21
3.15	Metode Domain-Specific Search	22
3.15.1	Patient Search	22
3.15.2	Encounter Search	22
3.15.3	Diagnosis Search	22
3.15.4	Medication Search	22
3.15.5	Laboratory Search	22
3.15.6	Procedure Search	23
3.16	Struktur Indeks	23
3.17	Pembentukan dan Pembaruan Indeks	23
3.18	Arsitektur Modul	23
3.19	Kontrak Input dan Output Sistem	24
3.20	Penyusunan Dataset Kueri	25
3.21	Ground Truth Relevansi	25
3.22	Pengujian Fungsional	26
3.23	Evaluasi Query Routing	26
3.24	Evaluasi Information Retrieval	26
3.25	Evaluasi Efisiensi	27
3.26	Metode Pembanding	27
3.27	Rancangan Eksperimen	28

3.28 Analisis Hasil	28
3.29 Penarikan Kesimpulan	28
BAB IV: JADWAL PENELITIAN	29
DAFTAR PUSTAKA	30

DAFTAR TABEL

2.1	Ringkasan penelitian terdahulu dan posisi penelitian	10
3.1	Entitas demo data OpenMRS dan domain pencarian	16
3.2	Contoh dataset kueri dan label domain	25
3.3	Konfigurasi model eksperimen	28
4.1	Jadwal Penelitian	29

DAFTAR GAMBAR

3.1 Alur penelitian pengembangan modul TF-IDF pada OpenMRS	13
--	----

BAB I

PENDAHULUAN

1.1 Latar Belakang

Transformasi digital dalam sektor kesehatan telah mendorong penggunaan *Electronic Medical Record* (EMR) sebagai sarana utama untuk mencatat, menyimpan, dan mengelola informasi pelayanan pasien. EMR mengintegrasikan berbagai jenis data, seperti identitas pasien, riwayat kunjungan, diagnosis, hasil pemeriksaan laboratorium, tindakan medis, resep obat, dan catatan klinis. Ketersediaan informasi tersebut dapat mendukung kontinuitas pelayanan serta membantu tenaga kesehatan memperoleh riwayat pasien secara lebih lengkap. Namun, bertambahnya volume dan keragaman data juga menimbulkan tantangan dalam menemukan kembali informasi yang relevan secara cepat (Campanella et al., 2016; Menachemi & Collum, 2011).

Salah satu platform EMR berbasis sumber terbuka yang digunakan secara luas adalah OpenMRS atau *Open Medical Record System*. OpenMRS dikembangkan sebagai platform EMR yang modular dan dapat dikustomisasi sesuai kebutuhan organisasi pelayanan kesehatan. Arsitektur OpenMRS terdiri atas basis data, *backend* berbasis Java, REST API, FHIR API, *frontend* berbasis JavaScript, serta mekanisme modul yang memungkinkan pengembang menambahkan fungsi baru tanpa harus mengubah keseluruhan kode inti aplikasi. Struktur tersebut memungkinkan pengembangan fitur pencarian sebagai modul tambahan yang tetap terintegrasi dengan sistem OpenMRS (Muinga et al., 2018; Purkayastha et al., 2019; Verma et al., 2021).

OpenMRS telah digunakan dalam berbagai konteks pelayanan kesehatan, mulai dari implementasi rutin hingga respons kedaruratan. Pengalaman tersebut menunjukkan bahwa platform yang sama dapat dikonfigurasi untuk kebutuhan organisasi dan alur pelayanan yang berbeda (Oza et al., 2017; Verma et al., 2021). Data pada OpenMRS dapat tersebar pada berbagai objek, seperti *Patient*, *Visit*, *Encounter*, *Observation*, *Diagnosis*, *Concept*, dan *Drug Order*. Sebagai contoh, hasil pemeriksaan laboratorium, tanda vital, dan temuan klinis dapat direpresentasikan sebagai *observation* yang berkaitan dengan pasien dan *encounter* tertentu.

Penyimpanan data dalam objek dan modul yang berbeda dapat menimbulkan kesulitan ketika pengguna ingin melakukan pencarian secara menyeluruh. Pengguna pada umumnya perlu mengetahui terlebih dahulu jenis data yang dicari, kemudian membuka menu atau modul yang sesuai. Pencarian pasien dilakukan melalui bagian registrasi pasien, pencarian diagnosis dilakukan pada informasi klinis atau konsep, sedangkan hasil laboratorium dicari melalui *observation* atau riwayat *encounter*. Mekanisme tersebut dapat digunakan dengan baik apabila pengguna telah memahami struktur sistem, tetapi menjadi kurang efisien ketika kebutuhan informasi melibatkan beberapa bidang sekaligus. Penelitian tentang pencarian EHR menunjukkan bahwa fungsi pencarian dibutuhkan untuk menemukan obat, diagnosis, hasil laboratorium, dan kejadian klinis secara lebih efisien (Hanauer et al., 2015; Hill et al., 2021; Ruppel et al., 2020).

Sebagai contoh, kueri “pasien diabetes yang menggunakan metformin” berhubungan dengan data pasien, diagnosis, *encounter*, dan obat. Sementara itu, kueri “hasil hemoglobin pasien Andi” melibatkan data pasien dan hasil laboratorium. Dalam kondisi tersebut, pengguna mungkin telah mengetahui informasi yang dibutuhkan, tetapi belum tentu memahami modul tempat informasi tersebut disimpan. Oleh karena itu, diperlukan mekanisme pencarian umum yang dapat menerima satu kueri, memperkirakan bidang yang relevan, kemudian mengarahkan proses pencarian ke sumber data yang sesuai.

Information Retrieval merupakan bidang yang mempelajari cara merepresentasikan, mencari, dan memeringkat informasi berdasarkan relevansinya terhadap kueri pengguna. Salah satu metode dasar yang banyak digunakan dalam *Information Retrieval* adalah *Term Frequency-Inverse Document Frequency* atau TF-IDF. Metode ini memberikan bobot terhadap suatu istilah berdasarkan frekuensi kemunculannya dalam sebuah dokumen dan tingkat kelangkaannya pada keseluruhan koleksi dokumen. Istilah yang sering muncul dalam suatu dokumen, tetapi relatif jarang muncul pada dokumen lain, akan memperoleh bobot yang lebih tinggi (Salton & Buckley, 1988; Spärck Jones, 1972).

Secara umum, bobot TF-IDF dihitung dengan mengalikan nilai *Term Frequency* dan *Inverse Document Frequency*. *Term Frequency* menunjukkan seberapa sering suatu istilah muncul dalam dokumen, sedangkan *Inverse Document Frequency* menunjukkan seberapa jarang istilah tersebut muncul pada seluruh koleksi. Dokumen dan kueri selanjutnya direpresentasikan dalam bentuk vektor. Tingkat kemiripan antara vektor kueri dan vektor dokumen kemudian dihitung menggunakan *cosine similarity*. Dokumen dengan nilai *cosine similarity* tertinggi dianggap memiliki tingkat relevansi yang lebih tinggi terhadap kueri pengguna (Salton & Buckley, 1988).

Dalam penelitian ini, TF-IDF digunakan pada dua tahap utama. Tahap pertama adalah *query routing*, yaitu proses menentukan bidang OpenMRS yang paling sesuai dengan isi kueri. Tahap kedua adalah *document retrieval*, yaitu proses memeringkat data pada bidang yang telah dipilih berdasarkan nilai *cosine similarity*. Bidang pencarian yang digunakan dapat mencakup data pasien, *encounter*, diagnosis, obat, hasil laboratorium, dan catatan klinis. Pemilihan domain sebelum pencarian mengadaptasi prinsip pemilihan koleksi dalam *federated search* (Powell et al., 2000; Shokouhi & Si, 2011).

Setiap bidang direpresentasikan melalui kumpulan istilah yang menggambarkan karakteristiknya. Sebagai contoh, bidang obat dapat direpresentasikan menggunakan istilah seperti *drug*, *medication*, *prescription*, *dosage*, *tablet*, dan berbagai nama obat. Bidang laboratorium dapat direpresentasikan menggunakan istilah seperti *laboratory*, *test*, *specimen*, *result*, *haemoglobin*, dan *blood glucose*. Kueri pengguna kemudian diubah menjadi vektor TF-IDF dan dibandingkan dengan profil setiap bidang. Bidang dengan nilai *cosine similarity* tertinggi selanjutnya dipilih sebagai tujuan pencarian.

Sebagai ilustrasi, kueri “metformin 500 mg untuk pasien diabetes” diperkirakan memiliki tingkat kemiripan yang tinggi dengan bidang obat, diagnosis, dan *encounter*. Sementara itu, kueri “hasil pemeriksaan gula darah tinggi” lebih sesuai dengan bidang laboratorium dan diagnosis. Sistem dapat memilih satu bidang dengan skor tertinggi atau beberapa bidang yang memiliki nilai kemiripan di atas ambang batas tertentu. Apabila seluruh skor *routing* rendah, sistem dapat menjalankan pencarian umum pada seluruh bidang sebagai mekanisme *fallback*.

TF-IDF pada dasarnya merupakan metode pencocokan leksikal dan belum mampu memahami kesamaan makna secara langsung. Sebagai contoh, TF-IDF dasar tidak secara otomatis mengetahui bahwa istilah *high blood pressure* memiliki hubungan dengan *hypertension*. Oleh karena itu, istilah *semantic query routing* dalam penelitian ini tidak merujuk pada penggunaan *embedding* atau model bahasa, tetapi pada mekanisme *routing* sederhana yang diperkaya dengan sinonim dan terminologi medis. Batasan tersebut membedakan pendekatan penelitian dari model bahasa biomedis kontekstual seperti BioBERT (Lee et al., 2020).

OpenMRS memiliki *Concept Dictionary* yang dapat menyimpan konsep klinis, nama utama, sinonim, serta istilah terkait. Informasi tersebut dapat dimanfaatkan untuk memperluas kueri sebelum perhitungan TF-IDF dilakukan. Sebagai contoh, kueri “high blood pressure treatment” dapat diperluas menjadi “high blood pressure hypertension elevated blood pressure treatment”. Demikian pula, singkatan seperti *SOB* dapat diperluas menjadi *shortness of breath*.

Pengayaan istilah tersebut dapat meningkatkan kemungkinan kecocokan antara istilah yang dimasukkan pengguna dan istilah yang tersimpan dalam OpenMRS. Walaupun menggunakan pengayaan istilah, algoritma utama yang digunakan tetap TF-IDF, sedangkan sinonim hanya berfungsi sebagai bagian dari tahap praproses (Aronson & Lang, 2010; Ye & Fabbri, 2018).

Berdasarkan permasalahan tersebut, penelitian ini mengusulkan pengembangan modul pencarian umum pada OpenMRS menggunakan TF-IDF dan *cosine similarity* yang dilengkapi dengan mekanisme *query routing* sederhana. Sistem menerima kueri melalui satu antarmuka pencarian, melakukan normalisasi dan pengayaan istilah, menghitung kemiripan kueri terhadap profil setiap bidang, memilih bidang yang relevan, kemudian melakukan pemeringkatan data menggunakan TF-IDF.

Kontribusi utama penelitian ini adalah penerapan TF-IDF sebagai metode pembobotan utama sekaligus sebagai dasar *query routing* pada sistem EMR yang memiliki struktur data modular dan heterogen. Pendekatan tersebut diharapkan dapat membantu pengguna menemukan informasi klinis secara lebih cepat tanpa harus memahami terlebih dahulu lokasi data dalam setiap modul OpenMRS.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana merancang mekanisme *query routing* berbasis TF-IDF yang mampu mengidentifikasi bidang atau sumber data OpenMRS yang paling relevan berdasarkan istilah, sinonim, dan konteks leksikal yang terdapat dalam kueri pengguna?
2. Bagaimana mengintegrasikan mekanisme *query routing* berbasis TF-IDF dengan sistem *Information Retrieval* pada OpenMRS sehingga pengguna dapat melakukan pencarian informasi secara umum maupun khusus tanpa harus mengetahui struktur modul atau lokasi penyimpanan data?
3. Bagaimana kinerja mekanisme *query routing* dan *Information Retrieval* berbasis TF-IDF yang dikembangkan dibandingkan dengan mekanisme pencarian konvensional pada OpenMRS, ditinjau dari ketepatan penentuan bidang pencarian, relevansi hasil temu kembali, dan efisiensi waktu pencarian?

1.3 Batasan Penelitian

Agar penelitian memiliki ruang lingkup yang jelas, terarah, dan dapat diselesaikan sesuai dengan tujuan yang telah ditetapkan, batasan penelitian ini dirumuskan sebagai berikut.

1. Sistem yang dikembangkan diimplementasikan sebagai modul tambahan pada OpenMRS tanpa melakukan perubahan langsung terhadap kode inti, proses bisnis utama, struktur autentikasi, maupun fungsi pelayanan klinis yang telah tersedia pada OpenMRS.
2. Pengembangan difokuskan pada mekanisme pencarian umum yang memungkinkan pengguna memasukkan satu kueri untuk mencari informasi pada beberapa bidang data OpenMRS tanpa harus memilih modul terlebih dahulu.

3. Bidang data yang menjadi ruang pencarian dibatasi pada data pasien, *encounter* atau kunjungan, diagnosis, obat atau *medication*, hasil pemeriksaan laboratorium, dan catatan klinis. Data dari modul lain di luar bidang tersebut tidak menjadi fokus utama penelitian.
4. Istilah *Semantic Query Routing* dalam penelitian ini dibatasi sebagai mekanisme *routing* berbasis kesamaan leksikal yang diperkaya dengan terminologi medis. Mekanisme tersebut tidak menggunakan *word embedding*, *transformer*, *large language model*, maupun metode *deep learning* untuk memahami makna kueri.
5. Penelitian tidak mengembangkan algoritma *Natural Language Processing* secara mendasar. Tahapan pemrosesan teks dibatasi pada normalisasi huruf, tokenisasi, penghapusan karakter yang tidak diperlukan, pengelolaan *stopword*, serta ekspansi istilah medis sederhana.

1.4 Tujuan Penelitian

Penelitian ini bertujuan untuk mengembangkan mekanisme *Semantic Query Routing* yang terintegrasi dengan sistem *Information Retrieval* pada platform OpenMRS guna meningkatkan efektivitas dan efisiensi pencarian informasi berbasis bahasa alami. Secara khusus, tujuan penelitian ini adalah sebagai berikut:

1. Merancang mekanisme *query routing* berbasis TF-IDF dan *cosine similarity* untuk menentukan satu atau beberapa domain data OpenMRS yang paling relevan berdasarkan kueri pengguna.
2. Mengimplementasikan modul pencarian pada OpenMRS yang mengintegrasikan *query routing* dengan pemeringkatan hasil berbasis TF-IDF pada domain *Patient*, *Encounter*, *Diagnosis*, *Medication*, *Laboratory*, dan *Procedure* menggunakan demo data resmi OpenMRS (OpenMRS, 2025).
3. Mengevaluasi kinerja sistem yang dikembangkan berdasarkan ketepatan *query routing*, relevansi hasil pencarian, dan waktu respons, serta membandingkannya dengan mekanisme pencarian konvensional pada OpenMRS.

1.5 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:

1. Memberikan kontribusi dalam pengembangan ilmu pengetahuan di bidang *Information Retrieval*, *Natural Language Processing* (NLP), dan *Electronic Medical Record* (EMR) melalui pengembangan mekanisme *Semantic Query Routing* untuk mendukung pencarian informasi berbasis bahasa alami.
2. Menghasilkan sebuah *framework Semantic Query Routing* yang mengintegrasikan proses pemahaman kueri, penentuan ruang pencarian, dan *Information Retrieval* pada sistem *Electronic Medical Record*, sehingga dapat menjadi referensi bagi penelitian selanjutnya.
3. Menjadi alternatif pengembangan fitur *global semantic search* pada OpenMRS yang memungkinkan pengguna melakukan pencarian informasi secara lebih intuitif tanpa harus mengetahui struktur modul atau lokasi penyimpanan data.

4. Membantu tenaga kesehatan, petugas administrasi, dan pengelola sistem dalam memperoleh informasi yang dibutuhkan secara lebih cepat, tepat, dan efisien sehingga dapat meningkatkan kemudahan penggunaan sistem serta mendukung efektivitas proses pelayanan kesehatan.
5. Menjadi referensi bagi pengembang sistem informasi kesehatan maupun sistem informasi *enterprise* lainnya dalam mengimplementasikan mekanisme pencarian berbasis semantik pada sistem yang memiliki struktur data modular dan heterogen.

BAB II

TINJAUAN PUSTAKA

2.1 Electronic Medical Record dan Kebutuhan Temu Kembali Informasi

Electronic Medical Record (EMR) dan *Electronic Health Record* (EHR) digunakan untuk menyimpan informasi longitudinal pasien, termasuk data demografis, kunjungan, diagnosis, obat, hasil pemeriksaan, prosedur, dan catatan klinis. Digitalisasi tersebut meningkatkan ketersediaan dan kesinambungan informasi, tetapi manfaatnya bergantung pada kemampuan sistem untuk menyajikan informasi yang tepat pada saat dibutuhkan. Kajian mengenai EHR menunjukkan bahwa sistem elektronik dapat mendukung kualitas, efisiensi, dan koordinasi pelayanan, sekaligus menimbulkan tantangan berupa beban dokumentasi, kompleksitas antarmuka, dan kesulitan menemukan informasi di dalam rekam medis yang terus bertambah (Campanella et al., 2016; Menachemi & Collum, 2011).

Ketersediaan data tidak selalu identik dengan ketersediaan informasi. Data klinis dapat tersebar pada banyak layar, modul, tipe dokumen, dan episode pelayanan. Penelitian tentang pola pencarian pengguna EHR menunjukkan bahwa tenaga kesehatan secara nyata menggunakan fungsi pencarian untuk menemukan obat, diagnosis, hasil laboratorium, dan kejadian klinis tertentu (Hill et al., 2021; Ruppel et al., 2020). Oleh karena itu, fungsi pencarian bukan sekadar fitur tambahan, tetapi merupakan komponen yang mendukung akses efektif terhadap data klinis.

2.2 OpenMRS

OpenMRS merupakan platform rekam medis sumber terbuka yang dikembangkan sebagai sistem modular dan dapat dikonfigurasi untuk berbagai konteks pelayanan kesehatan. Model modular memungkinkan fungsi tambahan dikembangkan tanpa mengubah keseluruhan kode inti. Karakteristik tersebut mendukung pengembangan modul pencarian yang terhubung dengan model data pasien, kunjungan, *encounter*, observasi, diagnosis, obat, dan konsep klinis. Pengalaman implementasi selama lebih dari satu dekade menunjukkan bahwa OpenMRS telah berkembang sebagai *global good* dengan komunitas, model implementasi, serta ekosistem modul yang luas (Verma et al., 2021).

Implementasi OpenMRS pada fasilitas kesehatan di Kenya memperlihatkan bahwa platform sumber terbuka dapat disesuaikan dengan kebutuhan layanan dan pelaporan setempat, tetapi keberhasilannya tetap dipengaruhi oleh infrastruktur, tata kelola, pelatihan, dukungan pengguna, dan kualitas implementasi (Muinga et al., 2018). Kajian perbandingan sistem EHR sumber terbuka juga menunjukkan bahwa OpenMRS memiliki keunggulan pada fleksibilitas dan performa tugas pengguna tertentu, meskipun kelengkapan fungsi sangat bergantung pada konfigurasi serta modul yang digunakan (Purkayastha et al., 2019).

Fleksibilitas OpenMRS telah dimanfaatkan dalam kondisi operasional yang beragam. Pengembangan OpenMRS-Ebola, misalnya, menunjukkan bahwa arsitektur modular dapat diadaptasi untuk membangun sistem rekam medis dalam situasi kedaruratan kesehatan (Oza et al., 2017). Temuan tersebut mendukung pemilihan OpenMRS sebagai lingkungan penelitian karena modul pencarian dapat dikembangkan sebagai komponen terpisah, diuji, dan diintegrasikan tanpa merancang ulang seluruh sistem rekam medis.

2.3 Information Retrieval pada Rekam Medis Elektronik

Information Retrieval (IR) mempelajari representasi, pencocokan, dan pemeringkatan dokumen berdasarkan kebutuhan informasi pengguna. Dalam konteks rekam medis, dokumen tidak selalu berbentuk artikel atau laporan panjang. Satu dokumen pencarian dapat dibentuk dari sebuah pasien, *encounter*, diagnosis, resep obat, hasil laboratorium, atau prosedur. Representasi tersebut memungkinkan data terstruktur dan tekstual diproses menggunakan pendekatan IR yang seragam.

Pengembangan EMERSE menunjukkan bahwa mesin pencari khusus EHR dapat mempercepat proses penelusuran catatan klinis dan mendukung penelitian maupun peninjauan rekam medis (Hanauer et al., 2015). Penelitian mengenai pencarian kolaboratif juga menunjukkan bahwa kebutuhan informasi klinis dapat melibatkan pembagian kueri, hasil, dan pengetahuan pencarian di antara pengguna (Zheng et al., 2011). Analisis kueri pada sistem pencarian klinis memperlihatkan bahwa kueri pengguna sering singkat, beragam, dan berkaitan dengan entitas klinis tertentu (Natarajan et al., 2010). Kajian yang lebih luas juga menemukan bahwa fungsi pencarian EHR dapat mengurangi waktu pencarian, jumlah klik, dan beban kognitif, walaupun kualitasnya masih dipengaruhi oleh terminologi, salah eja, singkatan, dan keterbatasan konteks (Hill et al., 2021).

Pencarian klinis berbeda dari pencarian dokumen umum karena data mengandung singkatan, sinonim, variasi penulisan, kode, negasi, nilai numerik, serta hubungan antarentitas. Selain itu, istilah yang sama dapat memiliki arti berbeda pada konteks yang berbeda. Konsekuensinya, sistem pencarian perlu menggabungkan pemeringkatan teks dengan metadata terstruktur dan pengetahuan domain yang sesuai.

2.4 TF-IDF dan Model Ruang Vektor

TF-IDF memberikan bobot tinggi kepada istilah yang sering muncul pada suatu dokumen tetapi relatif jarang pada keseluruhan koleksi. Dasar *inverse document frequency* dikembangkan untuk menggambarkan kekhususan istilah terhadap koleksi (Spärck Jones, 1972). Selanjutnya, berbagai konfigurasi pembobotan istilah, normalisasi, dan frekuensi sublinear dikaji sebagai dasar sistem temu kembali berbasis kata (Salton & Buckley, 1988).

Pada model ruang vektor, dokumen dan kueri direpresentasikan sebagai vektor dengan dimensi berupa istilah dalam *vocabulary*. Kemiripan dapat dihitung menggunakan *cosine similarity*. Pendekatan ini sesuai sebagai *baseline* penelitian karena transparan, relatif ringan, dapat diimplementasikan pada koleksi berukuran kecil hingga menengah, dan menghasilkan skor yang dapat ditelusuri kembali ke istilah yang cocok.

TF-IDF tetap memiliki keterbatasan. Metode ini terutama menangkap kesamaan leksikal dan tidak secara langsung memahami bahwa dua istilah berbeda dapat memiliki makna klinis yang sama. Metode tersebut juga dipengaruhi oleh pemilihan token, *stopword*, *n*-gram, panjang dokumen, serta distribusi istilah. Oleh sebab itu, penelitian ini menggunakan normalisasi istilah, unigram, bigram, sinonim, dan singkatan medis sebagai bagian dari praproses, tetapi tetap menempatkan TF-IDF sebagai algoritma pembobotan utama.

2.5 Query Routing dan Pencarian Multi-Domain

Data OpenMRS tersusun dalam beberapa domain yang mempunyai struktur dan karakteristik istilah berbeda. Kondisi ini serupa dengan *federated search*, yaitu satu kueri diarahkan ke satu atau beberapa koleksi yang diperkirakan paling relevan. Dalam *federated search*, pemilihan koleksi berpengaruh langsung terhadap efektivitas dan efisiensi hasil pencarian (Powell et al., 2000; Shokouhi & Si, 2011).

Pada penelitian ini, setiap domain diperlakukan sebagai koleksi pencarian tersendiri. Profil domain dibentuk dari nama atribut, istilah umum, sinonim, dan contoh data. Kueri dibandingkan dengan profil *Patient*, *Encounter*, *Diagnosis*, *Medication*, *Laboratory*, dan *Procedure*. Domain yang melampaui nilai ambang dipilih untuk proses *retrieval*. Pendekatan *multi-route* digunakan karena satu kueri dapat mengandung lebih dari satu kebutuhan, misalnya diagnosis sekaligus obat.

Pemeringkatan antardomain perlu dilakukan secara hati-hati karena setiap domain mempunyai *vocabulary*, jumlah dokumen, dan distribusi skor yang berbeda. Karena itu, rancangan penelitian menampilkan hasil secara berkelompok berdasarkan domain. Strategi tersebut menghindari anggapan bahwa skor dari seluruh indeks selalu dapat dibandingkan secara langsung.

2.6 Pemrosesan Teks dan Pengayaan Terminologi Medis

Pemrosesan teks klinis umumnya meliputi normalisasi karakter, tokenisasi, pengelolaan *stop-word*, penanganan singkatan, dan identifikasi konsep. Tinjauan sistematis menunjukkan bahwa informasi klinis tidak terstruktur dapat diubah menjadi representasi yang lebih terstandar, tetapi performanya sangat dipengaruhi oleh karakteristik korpus, terminologi, dan tujuan aplikasi (Kreimeyer et al., 2017; Wang et al., 2018).

MetaMap menunjukkan penggunaan pengetahuan terminologi untuk memetakan teks biomedis ke konsep terstandar (Aronson & Lang, 2010). Dalam lingkup yang lebih sederhana, pengayaan kueri dapat dilakukan menggunakan daftar sinonim, singkatan, dan istilah yang berasal dari kamus konsep. Penelitian terhadap pencarian rekam medis juga menunjukkan bahwa istilah serupa yang diperoleh dari representasi semantik dapat membantu proses peninjauan catatan (Ye & Fabbri, 2018).

Penelitian ini membatasi pengayaan pada mekanisme yang transparan dan dapat diaudit. Sinonim tidak menggantikan istilah asli, tetapi ditambahkan ke kueri. Kata negasi dipertahankan, sedangkan istilah dosis, satuan, dan kode klinis dinormalisasi dengan aturan yang terdokumentasi. Pembatasan tersebut penting agar peningkatan hasil dapat dikaitkan secara jelas dengan konfigurasi praproses dan bukan dengan model yang sulit dijelaskan.

2.7 Demo Data Resmi OpenMRS sebagai Dataset Penelitian

OpenMRS menyediakan demo data untuk kebutuhan pengembangan dan pengujian. Dokumentasi resminya menjelaskan dua mekanisme penyiapan data. Pada OpenMRS Reference Application, jumlah pasien demo ditentukan melalui properti global `referencedemodata.createDemoPatientsOnNextStartup`, kemudian aplikasi dijalankan ulang. Pada OpenMRS Platform, tersedia paket basis data contoh yang harus disesuaikan dengan versi Platform yang digunakan. Dokumentasi tersebut juga menyebutkan paket contoh yang mencakup sekitar

5.000 pasien dan 500.000 observasi serta paket berukuran besar untuk pengujian performa (OpenMRS, 2025).

Penggunaan demo data resmi memberikan keuntungan metodologis karena seluruh rekam telah berada dalam model data OpenMRS. Entitas *Patient*, *Visit*, *Encounter*, *Observation*, *Drug Order*, *Provider*, *Location*, dan konsep klinis dapat diperiksa langsung tanpa pemetaan dari format eksternal. Dengan demikian, penelitian berfokus pada pembentukan dokumen pencarian, pembangunan indeks, *query routing*, dan evaluasi hasil, bukan pada pengembangan *importer* lintas sistem.

Demo data tetap memiliki keterbatasan. Kelengkapan entitas dan distribusi kasus bergantung pada versi OpenMRS, modul yang terpasang, serta konfigurasi pembentukan data. Demo data juga tidak dimaksudkan untuk mewakili secara sempurna variasi dokumentasi dan alur pelayanan pada fasilitas kesehatan nyata. Oleh karena itu, versi aplikasi, konfigurasi properti global, jumlah rekam per entitas, dan cakupan domain dicatat sebagai bagian dari dokumentasi eksperimen.

2.8 Interoperabilitas dan Akses Data OpenMRS

Interoperabilitas memungkinkan data kesehatan dipertukarkan dan digunakan lintas aplikasi. FHIR menyediakan model sumber daya serta antarmuka berbasis web untuk pertukaran data kesehatan. SMART on FHIR menunjukkan bahwa standar tersebut dapat digunakan sebagai dasar aplikasi yang dapat dipasang pada berbagai sistem EHR (Mandel et al., 2016). Tinjauan implementasi FHIR menemukan peluang besar untuk integrasi sistem, tetapi juga mencatat tantangan pada profil implementasi, terminologi, keamanan, dan konsistensi sumber daya (Ayaz et al., 2021).

Interoperabilitas tidak hanya berarti data dapat dikirim, tetapi juga bahwa struktur dan maknanya dapat dipertahankan saat digunakan oleh sistem lain (Lehne et al., 2019). Dalam penelitian ini, FHIR tidak digunakan untuk mengimpor dataset eksternal karena demo data telah tersedia secara native pada OpenMRS. Data untuk indeks pencarian diakses melalui lapisan layanan, REST API, FHIR API apabila sumber dayanya tersedia, atau koneksi baca-saja ke basis data. Setiap jalur akses tetap harus mempertahankan UUID, relasi pasien-*encounter*, konsep klinis, dan hak akses pengguna.

2.9 Evaluasi Sistem Temu Kembali

Evaluasi penelitian dipisahkan menjadi evaluasi *query routing*, evaluasi hasil *retrieval*, evaluasi efisiensi, dan pengujian fungsional. Untuk *routing*, *precision*, *recall*, dan F1-score digunakan karena sistem dapat memilih beberapa domain sekaligus. Pelaporan *macro average* memerlukan setiap domain secara setara, sedangkan *micro average* menggabungkan seluruh keputusan prediksi.

Untuk hasil pencarian, Precision@k dan Recall@k mengukur kualitas pada sejumlah hasil teratas. Mean Reciprocal Rank menilai posisi hasil relevan pertama. NDCG digunakan ketika relevansi dinilai secara bertingkat karena metrik tersebut memberikan bobot lebih tinggi kepada dokumen relevan yang ditempatkan pada posisi atas (Järvelin & Kekäläinen, 2002).

Evaluasi juga membandingkan TF-IDF dengan *exact match* dan *keyword matching*. Perbandingan menggunakan dataset, kueri, jumlah hasil, dan perangkat yang sama. Waktu pembentukan indeks, waktu pemuatan, waktu respons, ukuran indeks, serta penggunaan memori

dicatat untuk menilai apakah peningkatan relevansi masih sesuai dengan biaya komputasinya.

2.10 Perkembangan Pencarian Semantik dan Posisi Penelitian

Model representasi kontekstual seperti BioBERT mampu mempelajari pola bahasa biomedis yang lebih kompleks dibandingkan pencocokan kata secara langsung (Lee et al., 2020). Pendekatan semantik tersebut berpotensi mengatasi sinonim dan variasi konteks, tetapi memerlukan sumber daya komputasi, proses pelatihan, dan evaluasi yang lebih kompleks. Model semantik juga tidak menghilangkan kebutuhan terhadap tata kelola data, evaluasi domain, dan penjelasan hasil.

Penelitian ini sengaja menempatkan TF-IDF sebagai pendekatan utama untuk menghasilkan sistem yang ringan, transparan, dan dapat direproduksi. Unsur “semantik” dibatasi pada pengayaan istilah dan pemilihan domain berdasarkan profil terminologi. Posisi tersebut membedakan penelitian ini dari *semantic search* berbasis *embedding* atau *transformer*.

Tabel 2.1: Ringkasan penelitian terdahulu dan posisi penelitian

Penelitian	Fokus utama	Relevansi dan celah penelitian
Hanauer et al. (2015)	Mesin pencari teks penuh pada EHR	Membuktikan manfaat pencarian khusus EHR, tetapi tidak berfokus pada routing domain OpenMRS.
Natarajan et al. (2010)	Analisis kueri klinis	Menunjukkan keragaman kebutuhan pengguna dan pentingnya memahami karakteristik kueri.
Verma et al. (2021)	Pengalaman implementasi OpenMRS	Menegaskan modularitas dan ekosistem OpenMRS, tetapi tidak membahas pemeringkatan lintas-domain berbasis TF-IDF.
OpenMRS (2025)	Demo data resmi OpenMRS	Menyediakan data native OpenMRS untuk pengembangan, pengujian, dan evaluasi tanpa pemetaan dataset eksternal.
Shokouhi & Si (2011)	Pemilihan koleksi pada federated search	Menjadi dasar konseptual untuk memilih domain sebelum retrieval.
Salton & Buckley (1988)	Pembobotan istilah TF-IDF	Menjadi dasar representasi kueri, profil domain, dan dokumen pencarian.
Ye & Fabbri (2018)	Pengayaan istilah pada penelusuran EMR	Mendukung penggunaan istilah terkait, tetapi penelitian ini membatasi pengayaan pada kamus yang transparan.
Lee et al. (2020)	Model bahasa biomedis kontekstual	Menjadi arah pengembangan lanjutan; tidak digunakan dalam model utama penelitian.

Berdasarkan kajian tersebut, celah penelitian terletak pada integrasi tiga komponen dalam satu modul OpenMRS: pembentukan dokumen dari beberapa domain klinis, *query routing* berbasis TF-IDF untuk memilih domain, dan pemeringkatan dokumen pada domain terpilih. Evaluasi dirancang untuk mengukur kontribusi setiap komponen melalui perbandingan *Basic TF-IDF*, *Improved TF-IDF*, dan *Routed TF-IDF*.

BAB III

METODOLOGI PENELITIAN

3.1 Alur Penelitian

Penelitian ini dilaksanakan melalui serangkaian tahapan yang sistematis mulai dari identifikasi permasalahan hingga penarikan kesimpulan. Setiap tahap menghasilkan keluaran yang digunakan sebagai masukan bagi tahap berikutnya. Tahapan penelitian meliputi identifikasi permasalahan, studi literatur, penyiapan demo data OpenMRS, verifikasi data dan relasi, analisis kebutuhan sistem, pembentukan dokumen pencarian, pembangunan indeks TF-IDF, pengembangan mekanisme *query routing*, implementasi modul pencarian, pengujian, evaluasi, serta analisis hasil penelitian. Rancangan tersebut menggabungkan karakteristik OpenMRS, penggunaan demo data resmi, dan prinsip temu kembali informasi (OpenMRS, 2025; Salton & Buckley, 1988; Verma et al., 2021).

Penelitian diawali dengan identifikasi permasalahan pada mekanisme pencarian informasi dalam OpenMRS. Identifikasi dilakukan untuk memahami bagaimana data pasien dan data klinis disimpan serta diakses melalui objek dan modul yang berbeda. Pengguna OpenMRS pada umumnya perlu mengetahui jenis dan lokasi data sebelum melakukan pencarian. Kondisi tersebut menjadi kurang efisien ketika satu kebutuhan informasi berkaitan dengan beberapa domain, seperti pasien, *encounter*, diagnosis, obat, hasil laboratorium, dan prosedur.

Setelah permasalahan diidentifikasi, dilakukan studi literatur mengenai *Electronic Medical Record*, OpenMRS, *Information Retrieval*, *Term Frequency-Inverse Document Frequency*, *cosine similarity*, *query routing*, *text preprocessing*, serta evaluasi sistem pencarian. Studi literatur digunakan untuk membangun dasar teoritis dan menentukan pendekatan penelitian yang sesuai dengan karakteristik data pada OpenMRS.

Tahap berikutnya adalah penyiapan demo data resmi OpenMRS pada lingkungan pengujian. Apabila penelitian menggunakan OpenMRS Reference Application, jumlah pasien demo ditetapkan melalui pengaturan `referencedemodata.createDemoPatientsOnNextStartup` dan aplikasi dijalankan ulang. Apabila menggunakan paket demo OpenMRS Platform, paket data yang digunakan dipilih sesuai versi Platform yang dipasang (OpenMRS, 2025).


Data yang telah tersedia pada instalasi OpenMRS diverifikasi tanpa proses pemetaan atau impor dari sumber eksternal. Verifikasi mencakup ketersediaan *Patient*, *Visit/Encounter*, *Observation*, *Drug Order*, *Provider*, *Location*, serta konsep klinis yang diperlukan. Entitas yang tersedia kemudian diekstraksi dan dikelompokkan ke dalam domain pencarian. Setiap *record* diubah menjadi dokumen tekstual berdasarkan atribut-atribut yang relevan, diproses menggunakan *text preprocessing*, dan direpresentasikan dengan TF-IDF.

Tahap pengembangan sistem mencakup pembangunan mekanisme *query routing* dan *Information Retrieval*. *Query routing* digunakan untuk menentukan satu atau beberapa domain yang paling relevan terhadap kueri pengguna. Setelah domain ditentukan, proses *Information Retrieval* dilakukan pada indeks TF-IDF milik domain tersebut. *Cosine similarity* digunakan untuk menghitung kemiripan antara kueri dan dokumen, sedangkan hasil pencarian diurutkan berdasarkan nilai kemiripan tertinggi (Salton & Buckley, 1988; Shokouhi & Si, 2011).

Pengujian dilakukan menggunakan kumpulan kueri berlabel yang disusun berdasarkan *record* yang benar-benar tersedia pada demo data OpenMRS. Pengujian mencakup ketepatan *query routing*, kualitas hasil pencarian, waktu respons, dan fungsi-fungsi modul. Hasil sistem

kemudian dibandingkan dengan pencarian konvensional berbasis *exact match* atau *keyword matching*.

Tahap terakhir adalah analisis hasil dan penarikan kesimpulan. Analisis dilakukan untuk menilai kemampuan TF-IDF dalam menentukan domain pencarian dan memeringkat dokumen, mengidentifikasi kesalahan sistem, serta menjawab tujuan penelitian.



Gambar 3.1: Alur penelitian pengembangan modul TF-IDF pada OpenMRS

3.2 Pendekatan Umum Penelitian

Penelitian ini menggunakan pendekatan pengembangan sistem dan eksperimen *Information Retrieval*. Pengembangan sistem dilakukan dengan membangun modul tambahan pada OpenMRS tanpa mengubah kode inti maupun proses bisnis utama OpenMRS, sesuai dengan karakter modular platform tersebut (Muinga et al., 2018; Verma et al., 2021). Eksperimen dilakukan untuk mengukur kemampuan TF-IDF dalam menentukan domain pencarian dan memeringkat hasil berdasarkan relevansi terhadap kueri pengguna.

Sistem menyediakan dua metode pencarian, yaitu *general search* dan *domain-specific search*. *General search* digunakan ketika pengguna tidak memilih domain pencarian. Sistem menentukan satu atau beberapa domain yang relevan secara otomatis menggunakan *query routing* berbasis TF-IDF dan *cosine similarity*. *Domain-specific search* digunakan ketika pengguna memilih domain tertentu secara langsung, sehingga *query routing* tidak perlu dijalankan.

Metode utama yang digunakan dalam penelitian adalah TF-IDF. Metode tersebut digunakan pada dua bagian sistem. Pertama, TF-IDF digunakan untuk merepresentasikan kueri dan profil domain dalam proses *query routing*. Kedua, TF-IDF digunakan untuk merepresentasikan kueri dan dokumen dalam proses *Information Retrieval* (Salton & Buckley, 1988; Spärck Jones, 1972).

Cosine similarity digunakan untuk menghitung kemiripan antara dua vektor TF-IDF. Dalam *query routing*, *cosine similarity* dihitung antara vektor kueri dan vektor profil domain. Dalam proses *retrieval*, *cosine similarity* dihitung antara vektor kueri dan vektor dokumen.

Istilah *query routing* dalam penelitian ini mengacu pada proses pemilihan ruang pencarian berdasarkan kesamaan leksikal dan mengadaptasi prinsip pemilihan koleksi pada *federated search* (Powell et al., 2000; Shokouhi & Si, 2011). Sistem tidak menggunakan *embedding*, *transformer*, *large language model*, atau *deep learning*. Oleh karena itu, sistem tidak diklaim memahami semantik secara penuh. Pengayaan istilah medis dilakukan secara sederhana melalui sinonim, singkatan, dan nama konsep agar pencocokan leksikal menjadi lebih baik.

3.3 Identifikasi Permasalahan

Tahap identifikasi permasalahan bertujuan untuk memahami keterbatasan mekanisme pencarian pada OpenMRS. Analisis dilakukan terhadap cara pengguna mencari pasien, kunjungan, diagnosis, obat, hasil laboratorium, dan prosedur.

Permasalahan pertama adalah data OpenMRS tersimpan dalam objek dan modul yang berbeda. Pencarian *Patient* dilakukan melalui fungsi registrasi atau *patient search*, sedangkan pencarian diagnosis, *observation*, *drug order*, dan *encounter* dilakukan melalui bagian yang berbeda. Pengguna harus memahami struktur sistem sebelum memilih tempat pencarian.

Permasalahan kedua adalah satu kueri dapat berkaitan dengan beberapa domain. Sebagai contoh, kueri “pasien diabetes yang menggunakan metformin” berkaitan dengan *Patient*, *Diagnosis*, *Medication*, dan *Encounter*. Pencarian yang terbatas pada satu modul tidak dapat secara langsung menghasilkan informasi lintas-domain tersebut.

Permasalahan ketiga adalah pencarian konvensional umumnya bergantung pada kecocokan atribut atau kata kunci. Pencarian tersebut belum menyediakan pemeringkatan dokumen berdasarkan tingkat relevansi. Oleh karena itu, diperlukan mekanisme yang mampu menentukan ruang pencarian dan mengurutkan hasil berdasarkan kedekatan terhadap kueri.

3.4 Studi Literatur

Studi literatur dilakukan untuk memperoleh dasar teori dan memahami penelitian terdahulu yang berkaitan dengan *Electronic Medical Record*, OpenMRS, *Information Retrieval*, TF-IDF, *cosine similarity*, *query routing*, *text preprocessing*, dan evaluasi sistem pencarian.

Kajian OpenMRS difokuskan pada model data, arsitektur modular, REST API, *Concept Dictionary*, sistem hak akses, serta mekanisme pengembangan modul. Kajian ini diperlukan agar modul pencarian dapat terintegrasi dengan OpenMRS tanpa mengubah kode inti aplikasi.

Kajian TF-IDF difokuskan pada pembobotan *term*, pembentukan *vocabulary*, perhitungan *document frequency*, normalisasi vektor, dan penggunaan *n*-gram. Kajian *cosine similarity* digunakan untuk memahami cara menentukan kedekatan antara kueri dan dokumen.

Kajian *query routing* digunakan untuk menentukan pendekatan pemilihan domain pencarian. Dalam penelitian ini, setiap domain diperlakukan sebagai koleksi yang memiliki profil terminologi sendiri. Kueri pengguna dibandingkan dengan seluruh profil domain untuk menentukan ruang pencarian yang sesuai.

Kajian evaluasi mencakup *accuracy*, *precision*, *recall*, F1-score, Precision@k, Recall@k, Mean Reciprocal Rank, Normalized Discounted Cumulative Gain, waktu pembentukan indeks, dan waktu respons pencarian.

3.5 Dataset Penelitian

Dataset utama penelitian menggunakan demo data resmi OpenMRS. Pada OpenMRS Reference Application, data disiapkan dengan mengisi properti global `referencedemodata.createDemoPatientsOnNextStartup` dan menjalankan ulang aplikasi. Dokumentasi OpenMRS juga menyediakan basis data contoh untuk OpenMRS Platform, tetapi versi data harus sesuai dengan versi Platform yang digunakan (OpenMRS, 2025).

Penelitian menetapkan OpenMRS Reference Application sebagai lingkungan utama agar pembentukan data dilakukan langsung oleh modul demo data OpenMRS. Pada tahap verifikasi awal, jumlah pasien ditetapkan antara 100 sampai 500 untuk memeriksa konfigurasi, relasi, dan proses ekstraksi. Setelah seluruh pemeriksaan berhasil, dataset eksperimen dibentuk dengan target sampai dengan 5.000 pasien, menyesuaikan kapasitas perangkat dan waktu pembangunan indeks.

Data yang digunakan berasal dari entitas native OpenMRS, meliputi *Patient*, *Person*, *Visit*, *Encounter*, *Observation*, *Order/Drug Order*, *Provider*, *Location*, dan *Concept*. Diagnosis, hasil laboratorium, obat, dan prosedur ditentukan dari entitas serta konsep klinis yang tersedia pada instalasi penelitian.

Versi OpenMRS, versi modul demo data, nilai properti global, jumlah rekam per entitas, dan tanggal pembentukan snapshot dicatat agar eksperimen dapat diulang. Penelitian tidak menggunakan data pasien nyata maupun dataset eksternal yang memerlukan pemetaan atau *Data Use Agreement*.

3.6 Inventarisasi Entitas dan Domain Pencarian

Demo data telah tersimpan dalam model data OpenMRS sehingga tidak diperlukan pemetaan dari skema eksternal. Tahap inventarisasi menentukan entitas sumber dan atribut yang digunakan untuk membentuk enam domain pencarian sebagaimana ditunjukkan pada Tabel 3.1.

Tabel 3.1: Entitas demo data OpenMRS dan domain pencarian

Entitas sumber OpenMRS	Domain pencarian	Atribut utama
<i>Patient, Person, Person Name, Person Address</i>	<i>Patient</i>	Identifier dan demografi
<i>Visit, Encounter, Encounter Type</i>	<i>Encounter</i>	Waktu, jenis, lokasi, dan tenaga kesehatan
<i>Encounter, Diagnosis, Condition, atau Observation</i> berkode	<i>Diagnosis</i>	Konsep, kode, nama, dan waktu diagnosis
<i>Drug Order, Drug, dan Order</i>	<i>Medication</i>	Nama obat, dosis, rute, dan status
<i>Observation dan Concept</i>	<i>Laboratory</i>	Nama pemeriksaan, hasil, satuan, dan interpretasi
<i>Procedure, Order, atau Observation</i> berkonsep prosedur	<i>Procedure</i>	Nama tindakan, kode, kategori, dan waktu
<i>Provider dan Location</i>	Seluruh domain terkait	Konteks tenaga kesehatan dan lokasi

Setiap dokumen indeks menyimpan UUID entitas sumber sehingga hasil pencarian dapat membuka rekam asli pada OpenMRS. Relasi *Visit–Encounter–Patient*, hubungan *Observation* dengan *Concept*, serta hubungan *Drug Order* dengan pasien dan *encounter* dipertahankan selama ekstraksi.

Diagnosis diambil dari struktur diagnosis yang tersedia pada versi OpenMRS atau dari *observation* berkode diagnosis. Hasil laboratorium dipilih berdasarkan konsep pemeriksaan dan tipe nilai *observation*. Prosedur diambil dari entitas prosedur, *order*, atau *observation* yang menggunakan konsep prosedur. Aturan pemilihan tersebut didokumentasikan agar pembentukan domain dapat diulang.

3.7 Penyiapan Demo Data OpenMRS

Penyiapan dimulai dengan mencatat versi OpenMRS Reference Application dan versi modul demo data. Jumlah pasien kemudian ditetapkan melalui properti global berikut.

```
referencedemodata.createDemoPatientsOnNextStartup
```

Administrator mengisi properti tersebut dengan jumlah pasien yang ditentukan, menyimpan perubahan, dan menjalankan ulang aplikasi (OpenMRS, 2025).

Setelah proses pembentukan selesai, nilai properti diperiksa kembali dan jumlah pasien diverifikasi. Basis data kemudian disimpan sebagai snapshot awal eksperimen. Snapshot yang sama digunakan untuk seluruh konfigurasi model agar perubahan hasil tidak disebabkan oleh perbedaan data.

Jika penelitian dijalankan pada OpenMRS Platform tanpa Reference Application, paket demo data harus dipilih sesuai versi Platform dan dimuat ke basis data pengujian. Jalur ini diperlakukan sebagai alternatif, bukan digabungkan dengan data Reference Application. Penelitian tidak mengembangkan *importer* CSV maupun FHIR karena tidak ada dataset eksternal yang dipindahkan ke OpenMRS.

3.8 Verifikasi Demo Data

Verifikasi jumlah dilakukan dengan menghitung *Patient*, *Visit*, *Encounter*, *Observation*, *Drug Order*, *Provider*, *Location*, dan konsep yang digunakan oleh setiap domain. Hasil hitung dicatat sebagai profil dataset dan dibandingkan kembali sebelum setiap rangkaian eksperimen.

Verifikasi relasi memastikan setiap *Encounter* terhubung dengan *Patient* yang benar. Diagnosis, obat, hasil laboratorium, dan prosedur juga harus dapat ditelusuri ke pasien atau *encounter* terkait. Rekam yang tidak memiliki relasi wajib tidak dimasukkan ke dalam indeks.

Verifikasi atribut dilakukan terhadap sampel data pada setiap domain. Atribut yang diperiksa mencakup identifier pasien, waktu *encounter*, konsep diagnosis, nama obat, nilai dan satuan *observation*, nama prosedur, *provider*, serta lokasi. Pembentukan indeks hanya dilakukan setelah keenam domain memenuhi kriteria kelengkapan yang ditetapkan sebelum eksperimen.

3.9 Domain Pencarian

Penelitian membatasi pencarian pada enam domain, yaitu *Patient*, *Encounter*, *Diagnosis*, *Medication*, *Laboratory*, dan *Procedure*.

Domain *Patient* digunakan untuk mencari pasien berdasarkan identifier, nama pasien demo, jenis kelamin, alamat, kota, dan informasi demografis. Domain *Encounter* digunakan untuk mencari riwayat kunjungan berdasarkan jenis *encounter*, lokasi, *provider*, diagnosis, obat, hasil pemeriksaan, dan tindakan.

Domain *Diagnosis* digunakan untuk mencari kondisi berdasarkan kode, nama diagnosis, sinonim, dan deskripsi. Domain *Medication* digunakan untuk mencari obat dan *drug order* berdasarkan nama obat, nama generik, kode, dosis, bentuk sediaan, dan rute pemberian.

Domain *Laboratory* digunakan untuk mencari hasil pemeriksaan berdasarkan nama pemeriksaan, kategori, nilai tekstual, interpretasi, satuan, dan waktu pemeriksaan. Domain *Procedure* digunakan untuk mencari tindakan berdasarkan nama, kode, kategori, dan deskripsi prosedur.

3.10 Pembentukan Dokumen Pencarian

Setiap *record* OpenMRS diubah menjadi dokumen tekstual sebelum diproses menggunakan TF-IDF. Pembentukan dokumen dilakukan oleh komponen *Document Builder* pada setiap domain.

Dokumen *Patient* dibentuk dari identifier, nama pasien demo, jenis kelamin, alamat, kota, wilayah, dan atribut demografis yang relevan.

```
patient identifier p10023
john smith
male
boston massachusetts
```

Dokumen *Encounter* dibentuk dari *encounter type*, lokasi, *provider*, diagnosis, *medication*, *observation*, *procedure*, dan ringkasan kunjungan.

```
ambulatory encounter
primary care clinic
type 2 diabetes mellitus
metformin
blood glucose examination
diabetes follow up
```

Dokumen *Diagnosis* dibentuk dari kode diagnosis, *preferred name*, sinonim, kategori, dan deskripsi.

```
e11
type 2 diabetes mellitus
adult onset diabetes
metabolic disease
```

Dokumen *Medication* dibentuk dari nama obat, nama generik, dosis, bentuk sediaan, rute, dan kondisi terkait.

```
metformin hydrochloride
500 milligram oral tablet
antidiabetic medication
type 2 diabetes treatment
```

Dokumen *Laboratory* dibentuk dari nama pemeriksaan, kategori, nilai hasil, satuan, interpretasi, dan konteks *encounter*.

```
blood glucose
laboratory observation
240 milligram per deciliter
abnormal high
diabetes monitoring
```

Dokumen *Procedure* dibentuk dari nama tindakan, kode, kategori, deskripsi, dan diagnosis terkait.

```
chest radiography
diagnostic imaging
pneumonia examination
hospital procedure
```


3.11 Text Preprocessing

Text preprocessing diterapkan dengan *pipeline* yang sama terhadap dokumen dan kueri. Kesamaan *pipeline* diperlukan agar *vocabulary* dan token yang dihasilkan konsisten. Tahapan ini mengikuti kebutuhan umum pemrosesan informasi klinis tidak terstruktur, terutama normalisasi, tokenisasi, terminologi, dan singkatan (Kreimeyer et al., 2017; Wang et al., 2018).

Tahap pertama adalah *case folding*, yaitu mengubah seluruh huruf menjadi huruf kecil. Tahap kedua adalah normalisasi karakter. Karakter yang tidak diperlukan dihapus atau diubah menjadi spasi, sedangkan karakter yang memiliki makna dalam kode atau istilah medis dipertahankan.

Tahap ketiga adalah tokenisasi. Teks dipecah menjadi token berdasarkan pola yang telah ditentukan. *Tokenizer* perlu mempertahankan istilah seperti *covid-19*, *hba1c*, *500mg*, dan kode diagnosis.

Tahap keempat adalah *stopword removal*. Kata umum yang tidak memberikan informasi penting dapat dihapus. Kata negasi seperti *no*, *not*, *without*, dan *negative* tidak dihapus secara otomatis karena dapat mengubah konteks klinis.

Tahap kelima adalah normalisasi istilah. Variasi penulisan dosis, satuan, dan singkatan dinormalisasi apabila diperlukan. Sebagai contoh, *mg.* dapat diubah menjadi *mg*, sedangkan *milligrams* dapat dinormalisasi menjadi *milligram*.

Tahap keenam adalah pembentukan unigram dan bigram. Unigram merepresentasikan kata tunggal, sedangkan bigram digunakan untuk mempertahankan frasa seperti *blood pressure*, *heart failure*, *type 2*, dan *chest pain*.

Tahap ketujuh adalah pengayaan kueri. Pengayaan dilakukan secara terbatas menggunakan sinonim dan singkatan medis. Contoh pengayaan adalah *high blood pressure* menjadi *high blood pressure hypertension*, serta *sob* menjadi *sob shortness of breath*. Pengayaan istilah hanya berfungsi sebagai praproses. Metode utama tetap TF-IDF (Aronson & Lang, 2010; Ye & Fabbri, 2018).

3.12 Metode TF-IDF

TF-IDF digunakan untuk memberikan bobot terhadap *term* berdasarkan frekuensinya dalam suatu dokumen dan kelangkaannya dalam keseluruhan koleksi (Salton & Buckley, 1988; Spärck Jones, 1972). Bobot TF-IDF dinyatakan sebagai:

$$\text{TFIDF}(t, d) = \text{TF}(t, d) \times \text{IDF}(t) \quad (1)$$

Keterangan: t adalah *term*; d adalah dokumen; $\text{TF}(t, d)$ adalah frekuensi *term* t pada dokumen d ; dan $\text{IDF}(t)$ adalah tingkat kelangkaan *term* t pada koleksi.

Term Frequency dasar dihitung sebagai:

$$\text{TF}(t, d) = f(t, d) \quad (2)$$

Untuk mengurangi pengaruh *term* yang muncul berulang kali, penelitian menggunakan *sublinear term frequency*:

$$\text{TF}_{\text{sublinear}}(t, d) = \begin{cases} 1 + \log f(t, d), & f(t, d) > 0, \\ 0, & f(t, d) = 0. \end{cases} \quad (3)$$

Inverse Document Frequency dihitung menggunakan *smoothing*:

$$\text{IDF}(t) = \log \left(\frac{N + 1}{df(t) + 1} \right) + 1 \quad (4)$$

Keterangan: N adalah jumlah seluruh dokumen dan $df(t)$ adalah jumlah dokumen yang memuat *term* t . Penambahan satu digunakan untuk mencegah pembagian dengan nol.

Konfigurasi utama TF-IDF menggunakan huruf kecil dan *sublinear term frequency*. Rentang n -gram ditetapkan pada unigram dan bigram, vektor dinormalisasi dengan normalisasi L2, sedangkan nilai `max_df` ditetapkan sebesar 0,95. Nilai `min_df` disesuaikan dengan ukuran koleksi: 1 untuk dataset kecil dan sekurang-kurangnya 2 untuk dataset yang lebih besar.

3.13 Cosine Similarity

Cosine similarity digunakan untuk menghitung kemiripan antara vektor kueri dan vektor dokumen:

$$\text{sim}(q, d) = \frac{\vec{q} \cdot \vec{d}}{\|\vec{q}\| \|\vec{d}\|} \quad (5)$$

Keterangan: $\vec{q}$ adalah vektor TF-IDF kueri; $\vec{d}$ adalah vektor TF-IDF dokumen; $\vec{q} \cdot \vec{d}$ adalah *dot product*; serta $\|\vec{q}\|$ dan $\|\vec{d}\|$ adalah panjang vektor.

Untuk vektor TF-IDF non-negatif, nilai *cosine similarity* berada pada rentang:

$$0 \leq \text{sim}(q, d) \leq 1 \quad (6)$$

Nilai yang mendekati 1 menunjukkan kemiripan yang lebih tinggi. Dokumen diurutkan berdasarkan skor tertinggi ke skor terendah. Dokumen dengan skor nol tidak ditampilkan.

3.14 Metode General Search

General search digunakan ketika pengguna tidak memilih domain. Sistem menjalankan *query routing* untuk menentukan satu atau beberapa domain pencarian yang relevan. Pendekatan ini sejalan dengan pemilihan sumber pada sistem pencarian terdistribusi (Powell et al., 2000; Shokouhi & Si, 2011).

3.14.1 Pembentukan Profil Domain

Setiap domain memiliki profil yang berisi istilah yang merepresentasikan karakteristik domain. Profil dibentuk dari nama *field*, istilah umum domain, sinonim, dan sebagian data yang tersedia. Contoh profil *Patient* berisi istilah *patient person identifier name gender age address city*

location. Profil *Encounter* berisi *encounter visit admission consultation emergency outpatient inpatient provider location follow up*. Profil *Diagnosis* berisi *diagnosis condition disease disorder symptom acute chronic diabetes hypertension pneumonia*. Profil *Medication* berisi *medication drug medicine prescription dosage tablet capsule metformin insulin antibiotic*. Profil *Laboratory* berisi *laboratory test observation result specimen blood glucose haemoglobin positive negative high low*. Profil *Procedure* berisi *procedure surgery imaging examination intervention operation treatment diagnostic*.

Profil domain diproses menggunakan *pipeline preprocessing* yang sama dengan dokumen dan kueri.

3.14.2 Perhitungan Skor Routing

Kueri pengguna ditransformasikan menjadi vektor TF-IDF. Selanjutnya, *cosine similarity* dihitung antara kueri dan setiap profil domain:

$$R(q, c) = \frac{\vec{q} \cdot \vec{c}}{\|\vec{q}\| \|\vec{c}\|} \quad (7)$$

Keterangan: q adalah kueri; c adalah profil domain; dan $R(q, c)$ adalah skor *routing*.

3.14.3 Pemilihan Domain

Penelitian menggunakan pendekatan *multi-route* karena satu kueri dapat berkaitan dengan lebih dari satu domain. Domain yang dipilih dirumuskan sebagai:

$$C_q = \{c \in C \mid R(q, c) \geq \tau\} \quad (8)$$

Keterangan: C adalah seluruh domain; C_q adalah domain yang dipilih untuk kueri q ; dan τ adalah nilai *threshold*.

Nilai *threshold* ditentukan melalui eksperimen menggunakan data pengembangan. Beberapa nilai yang dapat diuji adalah:

$$\tau \in \{0.10, 0.15, 0.20, 0.25, 0.30\} \quad (9)$$

Apabila tidak ada domain yang memenuhi *threshold*, sistem memilih domain dengan skor tertinggi atau menjalankan pencarian pada seluruh domain sebagai *fallback*.

3.14.4 Retrieval pada Domain Terpilih

Setelah domain ditentukan, kueri dicari pada setiap indeks domain terpilih. Setiap domain memiliki *vectorizer* dan matriks TF-IDF tersendiri. Hasil *general search* ditampilkan secara berkelompok berdasarkan domain karena distribusi skor *cosine similarity* dapat berbeda pada setiap domain.

3.15 Metode Domain-Specific Search

Domain-specific search digunakan ketika pengguna memilih domain secara langsung. Pada metode ini, *query routing* tidak dijalankan. Alurnya adalah input kueri, *text preprocessing*, pengayaan istilah, transformasi TF-IDF, *cosine similarity*, pemeringkatan, dan penyajian hasil.

3.15.1 Patient Search

Patient Search menggunakan identifier, nama, jenis kelamin, alamat, kota, dan lokasi. TF-IDF digunakan untuk pencarian berbasis teks, sedangkan *exact-match boosting* digunakan untuk identifier dan nama:

$$S_{\text{patient}} = S_{\text{TFIDF}} + B_{\text{identifier}} + B_{\text{name}} + B_{\text{prefix}} \quad (10)$$

3.15.2 Encounter Search

Encounter Search menggunakan jenis *encounter*, lokasi, *provider*, diagnosis, *observation*, *medication*, *procedure*, dan ringkasan *encounter*. Skor *encounter* dapat dihitung menggunakan pembobotan *field*:

$$S_{\text{encounter}} = 3S_{\text{diagnosis}} + 2S_{\text{observation}} + 1.5S_{\text{medication}} + 1.5S_{\text{procedure}} + S_{\text{location}} \quad (11)$$

3.15.3 Diagnosis Search

Diagnosis Search menggunakan *preferred name*, sinonim, kode, dan deskripsi:

$$S_{\text{diagnosis}} = 3S_{\text{preferred}} + 2S_{\text{synonym}} + 1.5S_{\text{code}} + S_{\text{description}} \quad (12)$$

3.15.4 Medication Search

Medication Search menggunakan nama obat, nama generik, dosis, bentuk sediaan, rute, dan indikasi:

$$S_{\text{medication}} = 3S_{\text{drug name}} + 2S_{\text{generic name}} + 1.5S_{\text{indication}} + S_{\text{dosage}} \quad (13)$$

3.15.5 Laboratory Search

Laboratory Search menggunakan nama pemeriksaan, kategori, hasil tekstual, interpretasi, dan satuan:

$$S_{\text{laboratory}} = 3S_{\text{test name}} + 2S_{\text{interpretation}} + S_{\text{category}} + S_{\text{unit}} \quad (14)$$

Nilai numerik disimpan sebagai metadata terstruktur. Jika pengguna memasukkan rentang nilai, pencarian dilakukan dengan gabungan TF-IDF dan filter basis data.

3.15.6 Procedure Search

Procedure Search menggunakan nama prosedur, sinonim, kode, kategori, dan deskripsi:

$$S_{\text{procedure}} = 3S_{\text{procedure name}} + 2S_{\text{synonym}} + 1.5S_{\text{code}} + S_{\text{description}} \quad (15)$$

3.16 Struktur Indeks

Metadata dokumen pencarian dibagi menjadi tiga kelompok. Identitas dokumen mencakup `document_id`, `entity_type`, dan `entity_uuid`. Konten pencarian mencakup `title`, `raw_content`, `processed_content`, serta `field_content`. Informasi pendukung mencakup `metadata`, `source_updated_at`, `indexed_at`, dan `index_version`.

`document_id` merupakan identifier dokumen dalam modul pencarian. `entity_type` menunjukkan domain dokumen. `entity_uuid` digunakan untuk membuka *record* asli pada OpenMRS. `raw_content` menyimpan teks sebelum *preprocessing*, sedangkan `processed_content` menyimpan hasil *preprocessing*. `field_content` menyimpan teks per *field* untuk mendukung *field-aware TF-IDF*. `metadata` menyimpan atribut tambahan, seperti tanggal, lokasi, status, dan nilai numerik.

Vocabulary, nilai IDF, dan matriks *sparse* dapat disimpan dalam file indeks atau *cache* aplikasi. Metadata dokumen tetap disimpan dalam basis data.

3.17 Pembentukan dan Pembaruan Indeks

Proses *full indexing* meliputi pengambilan data dari OpenMRS, pembentukan dokumen, *preprocessing*, pelatihan *vectorizer*, pembentukan matriks *sparse*, penyimpanan *vocabulary*, penyimpanan nilai IDF, dan penyimpanan metadata dokumen.

Full rebuild dilakukan apabila demo data dibentuk ulang atau diganti, konfigurasi *preprocessing* berubah, daftar sinonim berubah, struktur dokumen berubah, atau jumlah perubahan data cukup besar.

Pada versi penelitian, pembaruan indeks dapat dijalankan secara manual melalui menu admin atau *command*, misalnya *Rebuild All Indexes*, *Rebuild Patient Index*, *Rebuild Encounter Index*, *Rebuild Diagnosis Index*, *Rebuild Medication Index*, *Rebuild Laboratory Index*, dan *Rebuild Procedure Index*.

Pembaruan inkremental tidak menjadi fokus utama karena perubahan jumlah dokumen dan *document frequency* dapat memengaruhi nilai IDF seluruh koleksi.

3.18 Arsitektur Modul

Sistem dikembangkan sebagai modul tambahan pada OpenMRS. Komponen modul terdiri atas *OpenMRS Data Access*, *Dataset Validator*, *Document Builder*, *Text Preprocessor*, *TF-IDF Index*

Manager, Query Router, Domain Retriever, Search Service, REST API, Search Interface, dan Evaluation Utility.

OpenMRS Data Access bertugas membaca entitas demo data melalui layanan atau API OpenMRS dengan mempertahankan UUID dan relasinya. *Dataset Validator* memeriksa jumlah, kelengkapan atribut, dan hubungan antarentitas sebelum indeks dibangun. *Document Builder* membentuk dokumen tekstual dari entitas OpenMRS. *Text Preprocessor* menjalankan *pipeline preprocessing* pada dokumen dan kueri. *TF-IDF Index Manager* membangun, menyimpan, memuat, dan memperbarui indeks. *Query Router* menentukan domain yang relevan, sedangkan *Domain Retriever* melakukan pencarian dalam domain tertentu. *Search Service* mengoordinasikan seluruh proses pencarian. REST API menyediakan *endpoint* untuk *frontend*. *Search Interface* menyediakan kotak pencarian, pilihan domain, *filter*, dan daftar hasil. *Evaluation Utility* digunakan untuk menjalankan kueri evaluasi dan menghitung metrik.

3.19 Kontrak Input dan Output Sistem

Request general search dirancang sebagai berikut:

```
{
  "query": "diabetes patient taking metformin",
  "mode": "general",
  "limit": 10,
  "filters": {}
}
```

Request domain-specific search dirancang sebagai berikut:

```
{
  "query": "metformin 500 mg tablet",
  "mode": "specific",
  "domain": "medication",
  "limit": 10,
  "filters": {}
}
```

Response pencarian dirancang sebagai berikut:

```
{
  "query": "diabetes patient taking metformin",
  "selectedDomains": [
    {"domain": "diagnosis", "routingScore": 0.72},
    {"domain": "medication", "routingScore": 0.68}
  ],
  "results": [
    {
      "entityType": "diagnosis",
      "entityUuid": "record-uuid",
      "title": "Type 2 diabetes mellitus",

```

```

    "score": 0.84,
    "matchedTerms": ["diabetes"],
    "metadata": {}
  }
],
"responseTimeMs": 42
}

```

Kontrak tersebut digunakan sebagai acuan implementasi *backend*, *frontend*, *unit test*, dan pengembangan menggunakan AI *agent*.

3.20 Penyusunan Dataset Kueri

Demo data OpenMRS menyediakan rekam klinis untuk pengembangan, tetapi tidak menyediakan kumpulan kueri dan label relevansi untuk evaluasi sistem pencarian. Oleh karena itu, penelitian menyusun dataset kueri berdasarkan *record* yang benar-benar tersedia pada snapshot demo data penelitian.

Tabel 3.2: Contoh dataset kueri dan label domain

Kueri	Label domain
<i>patient named john smith</i>	<i>Patient</i>
<i>emergency hospital encounter</i>	<i>Encounter</i>
<i>type 2 diabetes diagnosis</i>	<i>Diagnosis</i>
<i>metformin 500 mg tablet</i>	<i>Medication</i>
<i>high blood glucose result</i>	<i>Laboratory</i>
<i>chest radiography procedure</i>	<i>Procedure</i>
<i>diabetes patient taking metformin</i>	<i>Patient, Diagnosis, Medication</i>
<i>emergency encounter with blood test</i>	<i>Encounter, Laboratory</i>

Dataset *routing* disarankan memiliki sekurang-kurangnya 300 kueri dengan distribusi yang relatif seimbang. Dataset dibagi menjadi data pengembangan dan data pengujian. Data pengembangan digunakan untuk menyusun profil domain, memilih nilai *threshold*, dan menentukan konfigurasi. Data pengujian hanya digunakan untuk evaluasi akhir. Penyusunan kueri mempertimbangkan temuan bahwa kebutuhan pencarian klinis umumnya singkat dan berorientasi pada entitas atau kejadian tertentu (Natarajan et al., 2010; Ruppel et al., 2020).

3.21 Ground Truth Relevansi

Setiap kueri *retrieval* diberi daftar dokumen yang relevan. Penilaian relevansi menggunakan skala:

$$\text{rel}(q, d) \in \{0, 1, 2\} \quad (16)$$

Nilai 0 berarti tidak relevan, nilai 1 berarti cukup relevan, dan nilai 2 berarti sangat relevan. Penilaian dilakukan oleh sekurang-kurangnya dua anggota kelompok. Apabila terdapat perbedaan, dilakukan diskusi atau penilaian oleh anggota ketiga.

3.22 Pengujian Fungsional

Pengujian fungsional dilakukan untuk memastikan seluruh komponen berjalan sesuai kebutuhan. Skenario pengujian mencakup demo data dapat dibaca melalui lapisan akses OpenMRS; validator menghasilkan jumlah entitas dan relasi yang benar; pembentukan ulang dataset tidak mencampur snapshot eksperimen; indeks dapat dibangun dan dimuat kembali; *general search* dapat menentukan domain; *domain-specific search* hanya mencari pada domain terpilih; hasil dapat diurutkan berdasarkan skor; *exact match* bekerja pada identifier; *filter* terstruktur dapat diterapkan; *record* OpenMRS dapat dibuka dari hasil pencarian; hak akses pengguna diterapkan; serta sistem mampu menangani kueri kosong, kueri tanpa hasil, dan indeks yang belum dibangun.

Pengujian dilakukan menggunakan *unit testing*, *integration testing*, dan *black-box testing*.

3.23 Evaluasi Query Routing

Evaluasi *query routing* dilakukan dengan membandingkan domain hasil prediksi dan label aktual. Untuk setiap domain, *precision* dihitung sebagai:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (17)$$

Recall dihitung sebagai:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (18)$$

F1-score dihitung sebagai:

$$F1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (19)$$

Untuk *single-label routing*, *accuracy* dapat dihitung sebagai:

$$\text{Accuracy} = \frac{\text{jumlah prediksi benar}}{\text{jumlah seluruh kueri}} \quad (20)$$

Karena sistem mendukung *multi-route*, hasil utama dilaporkan menggunakan *precision*, *recall*, dan F1-score secara *macro* dan *micro*.

3.24 Evaluasi Information Retrieval

Precision@k digunakan untuk mengukur proporsi dokumen relevan pada k hasil teratas:

$$\text{Precision @}k = \frac{\text{jumlah dokumen relevan pada } k \text{ hasil teratas}}{k} \quad (21)$$

Recall@k digunakan untuk mengukur proporsi dokumen relevan yang berhasil ditemukan:

$$\text{Recall @}k = \frac{\text{jumlah dokumen relevan pada } k \text{ hasil teratas}}{\text{jumlah seluruh dokumen relevan}} \quad (22)$$

Mean Reciprocal Rank digunakan untuk menilai posisi dokumen relevan pertama:

$$\text{MRR} = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{\text{rank}_i} \quad (23)$$

Discounted Cumulative Gain dihitung sebagai:

$$\text{DCG @}k = \sum_{i=1}^k \frac{2^{\text{rel}_i} - 1}{\log_2(i + 1)} \quad (24)$$

Normalized Discounted Cumulative Gain digunakan untuk memberikan penghargaan lebih besar kepada dokumen relevan yang ditempatkan pada posisi atas (Järvelin & Kekäläinen, 2002). Nilainya dihitung sebagai:

$$\text{NDCG @}k = \frac{\text{DCG @}k}{\text{IDCG @}k} \quad (25)$$

Nilai NDCG berada pada rentang 0 sampai 1. Nilai yang lebih tinggi menunjukkan bahwa dokumen dengan relevansi lebih tinggi ditempatkan lebih dekat ke posisi atas.

3.25 Evaluasi Efisiensi

Evaluasi efisiensi mencakup waktu pembentukan indeks, waktu pemuatan indeks, rata-rata waktu respons, median waktu respons, persentil ke-95, ukuran indeks, dan penggunaan memori.

Waktu respons didefinisikan sebagai:

$$T_{\text{response}} = T_{\text{output}} - T_{\text{request}} \quad (26)$$

Pengukuran dilakukan beberapa kali menggunakan kondisi perangkat dan dataset yang sama.

3.26 Metode Pembandingan

Metode usulan dibandingkan dengan pencarian konvensional. *Baseline* pertama adalah *exact match*, yaitu *record* dianggap cocok apabila nilai *field* sama persis dengan kueri. *Baseline* kedua adalah *keyword matching* menggunakan *substring* atau SQL LIKE. Model usulan adalah TF-IDF dengan *cosine similarity* dan *query routing*.

Perbandingan dilakukan menggunakan dataset, kueri, jumlah hasil, perangkat, dan konfigurasi pengujian yang sama.

3.27 Rancangan Eksperimen

Penelitian menggunakan tiga konfigurasi eksperimen sebagaimana ditunjukkan pada Tabel 3.3.

Tabel 3.3: Konfigurasi model eksperimen

Model	<i>Query routing</i>	<i>N</i> -gram	<i>Sublinear TF</i>	Pengayaan
Basic TF-IDF	Tidak	Unigram	Tidak	Tidak
Improved TF-IDF	Tidak	Unigram dan bigram	Ya	Ya
Routed TF-IDF	Ya	Unigram dan bigram	Ya	Ya

Model pertama adalah *Basic TF-IDF*, yang menggunakan unigram, *cosine similarity*, dan tidak menggunakan *query routing*. Model kedua adalah *Improved TF-IDF*, yang menggunakan unigram, bigram, *sublinear term frequency*, dan pengayaan istilah sederhana. Model ketiga adalah *Routed TF-IDF*, yang menggunakan *Improved TF-IDF* dan *query routing*. Perbandingan tersebut digunakan untuk menilai pengaruh *n*-gram, *sublinear TF*, pengayaan istilah, dan *query routing*.

3.28 Analisis Hasil

Analisis hasil mencakup ketepatan *routing*, kualitas *retrieval*, waktu respons, dan hasil pengujian fungsional. Analisis kesalahan dilakukan terhadap kueri yang salah rute, kueri multi-domain, istilah yang tidak tersedia dalam *vocabulary*, salah eja, *query* dengan skor rendah, dokumen relevan yang tidak muncul, dominasi domain, pengaruh panjang dokumen, dan pengaruh pengayaan sinonim.

Hasil analisis digunakan untuk menjelaskan kondisi ketika TF-IDF bekerja dengan baik dan kondisi ketika TF-IDF memiliki keterbatasan.

3.29 Penarikan Kesimpulan

Kesimpulan disusun berdasarkan tujuan penelitian dan hasil eksperimen. Kesimpulan menjelaskan kemampuan TF-IDF dalam mendukung *general search*, *domain-specific search*, *query routing*, dan pemeringkatan data pada OpenMRS.

Penelitian juga menjelaskan apakah metode yang diusulkan menghasilkan kinerja yang lebih baik dibandingkan *exact match* dan *keyword matching*. Keterbatasan sistem, seperti ketergantungan pada kesamaan kata, kamus sinonim, kualitas profil domain, kelengkapan modul, dan representativitas demo data OpenMRS, dicantumkan secara eksplisit.

Rekomendasi penelitian selanjutnya dapat mencakup penggunaan *word embedding*, *semantic search*, *learning-to-rank*, indeks inkremental, kamus istilah medis yang lebih lengkap, dan pengujian dengan pengguna OpenMRS yang sebenarnya. Model bahasa biomedis seperti BioBERT dapat digunakan sebagai pembanding semantik pada penelitian lanjutan (Lee et al., 2020).

BAB IV

JADWAL PENELITIAN

Jadwal penelitian disusun sebagai pedoman pelaksanaan penelitian agar setiap tahapan dapat dilaksanakan secara sistematis sesuai dengan target waktu yang telah ditentukan. Penelitian ini direncanakan berlangsung selama enam minggu, dimulai dari tahap analisis dan perencanaan, dilanjutkan dengan perancangan sistem, implementasi, pengujian dan evaluasi, hingga penyusunan laporan hasil penelitian. Rincian jadwal penelitian disajikan pada Tabel 4.1.

Tabel 4.1: Jadwal Penelitian

Aktivitas	25 Jul 2026	1 Agu 2026	8 Agu 2026	15 Agu 2026	22 Agu 2026	29 Agu 2026
Identifikasi Permasalahan	✓					
Studi Literatur	✓	✓				
Analisis Kebutuhan Sistem	✓	✓				
Perancangan Arsitektur Sistem		✓	✓			
Perancangan <i>Framework Semantic Query Routing</i>		✓	✓			
Perancangan <i>Information Retrieval</i> Berbasis TF-IDF			✓			
Implementasi dan Integrasi Sistem			✓	✓		
Pengujian Fungsional				✓		
Evaluasi <i>Information Retrieval</i>				✓	✓	
Analisis Hasil Pengujian					✓	
Penyusunan Laporan Penelitian					✓	✓
Finalisasi Laporan						✓

DAFTAR PUSTAKA

- Aronson, A. R., & Lang, F.-M. (2010). An overview of MetaMap: Historical perspective and recent advances. *Journal of the American Medical Informatics Association*, 17(3), 229–236. <https://doi.org/10.1136/jamia.2009.002733>
- Ayaz, M., Pasha, M. F., Alzahrani, M. Y., Budiarto, R., & Stiawan, D. (2021). The fast health interoperability resources (FHIR) standard: Systematic literature review of implementations, applications, challenges and opportunities. *JMIR Medical Informatics*, 9(7), Article e21929. <https://doi.org/10.2196/21929>
- Campanella, P., Lovato, E., Marone, C., Fallacara, L., Mancuso, A., Ricciardi, W., & Specchia, M. L. (2016). The impact of electronic health records on healthcare quality: A systematic review and meta-analysis. *European Journal of Public Health*, 26(1), 60–64. <https://doi.org/10.1093/eurpub/ckv122>
- Hanauer, D. A., Mei, Q., Law, J., Khanna, R., & Zheng, K. (2015). Supporting information retrieval from electronic health records: A report of university of michigan’s nine-year experience in developing and using the electronic medical record search engine (EMERSE). *Journal of Biomedical Informatics*, 55, 290–300. <https://doi.org/10.1016/j.jbi.2015.05.003>
- Hill, J. R., Visweswaran, S., Ning, X., & Schleyer, T. K. (2021). Use, impact, weaknesses, and advanced features of search functions for clinical use in electronic health records: A scoping review. *Applied Clinical Informatics*, 12(3), 417–428. <https://doi.org/10.1055/s-0041-1730033>
- Järvelin, K., & Kekäläinen, J. (2002). Cumulated gain-based evaluation of IR techniques. *ACM Transactions on Information Systems*, 20(4), 422–446. <https://doi.org/10.1145/582415.582418>
- Kreimeyer, K., Foster, M., Pandey, A., Arya, N., Halford, G., Jones, S. F., Forshee, R., Walderhaug, M., & Botsis, T. (2017). Natural language processing systems for capturing and standardizing unstructured clinical information: A systematic review. *Journal of Biomedical Informatics*, 73, 14–29. <https://doi.org/10.1016/j.jbi.2017.07.012>
- Lee, J., Yoon, W., Kim, S., Kim, D., Kim, S., So, C. H., & Kang, J. (2020). BioBERT: A pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics*, 36(4), 1234–1240. <https://doi.org/10.1093/bioinformatics/btz682>
- Lehne, M., Luijten, S., vom Felde genannt Imbusch, P., & Thun, S. (2019). Why digital medicine depends on interoperability. *npj Digital Medicine*, 2, Article 79. <https://doi.org/10.1038/s41746-019-0158-1>
- Mandel, J. C., Kreda, D. A., Mandl, K. D., Kohane, I. S., & Ramoni, R. B. (2016). SMART on FHIR: A standards-based, interoperable apps platform for electronic health records. *Journal of the American Medical Informatics Association*, 23(5), 899–908. <https://doi.org/10.1093/jamia/ocv189>
- Menachemi, N., & Collum, T. H. (2011). Benefits and drawbacks of electronic health record systems. *Risk Management and Healthcare Policy*, 4, 47–55. <https://doi.org/10.2147/RMHP.S12985>
- Muinga, N., Magare, S., Monda, J., Kamau, O., Houston, S., Fraser, H., Powell, J., English, M., & Paton, C. (2018). Implementing an open source electronic health record system in kenyan health care facilities: Case study. *JMIR Medical Informatics*, 6(2), Article e22. <https://doi.org/10.2196/medinform.8403>
- Natarajan, K., Stein, D., Jain, S., & Elhadad, N. (2010). An analysis of clinical queries in an electronic health record search utility. *International Journal of Medical Informatics*, 79(7), 515–522. <https://doi.org/10.1016/j.ijmedinf.2010.03.004>
- OpenMRS. (2025, January 10). *Demo data*. OpenMRS Wiki. Retrieved July 26, 2026, from <https://openmrs.atlassian.net/wiki/spaces/docs/pages/26273323/Demo+Data>

- Oza, S., Jazayeri, D., Teich, J. M., Ball, E., Nankubuge, P. A., Rwebembera, J., Wing, K., Sesay, A. A., Kanter, A. S., Ramos, G. D., Walton, D., Cummings, R., Checchi, F., & Fraser, H. S. (2017). Development and deployment of the OpenMRS-Ebola electronic health record system for an ebola treatment center in sierra leone. *Journal of Medical Internet Research*, 19(8), Article e294. <https://doi.org/10.2196/jmir.7881>
- Powell, A. L., French, J. C., Callan, J., Connell, M., & Viles, C. L. (2000). The impact of database selection on distributed searching. *Proceedings of the 23rd Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, 232–239. <https://doi.org/10.1145/345508.345584>
- Purkayastha, S., Allam, R., Maity, P., & Gichoya, J. W. (2019). Comparison of open-source electronic health record systems based on functional and user performance criteria. *Health-care Informatics Research*, 25(2), 89–98. <https://doi.org/10.4258/hir.2019.25.2.89>
- Ruppel, H., Bhardwaj, A., Manickam, R. N., Adler-Milstein, J., Flagg, M., Ballesca, M., & Liu, V. X. (2020). Assessment of electronic health record search patterns and practices by practitioners in a large integrated health care system. *JAMA Network Open*, 3(3), Article e200512. <https://doi.org/10.1001/jamanetworkopen.2020.0512>
- Salton, G., & Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5), 513–523. [https://doi.org/10.1016/0306-4573\(88\)90021-0](https://doi.org/10.1016/0306-4573(88)90021-0)
- Shokouhi, M., & Si, L. (2011). Federated search. *Foundations and Trends in Information Retrieval*, 5(1), 1–102. <https://doi.org/10.1561/15000000010>
- Spärck Jones, K. (1972). A statistical interpretation of term specificity and its application in retrieval. *Journal of Documentation*, 28(1), 11–21. <https://doi.org/10.1108/eb026526>
- Verma, N., Mamlin, B., Flowers, J., Acharya, S., Labrique, A., & Cullen, T. (2021). OpenMRS as a global good: Impact, opportunities, challenges, and lessons learned from fifteen years of implementation. *International Journal of Medical Informatics*, 149, Article 104405. <https://doi.org/10.1016/j.ijmedinf.2021.104405>
- Wang, Y., Wang, L., Rastegar-Mojarad, M., Moon, S., Shen, F., Afzal, N., Liu, S., Zeng, Y., Mehrabi, S., Sohn, S., & Liu, H. (2018). Clinical information extraction applications: A literature review. *Journal of Biomedical Informatics*, 77, 34–49. <https://doi.org/10.1016/j.jbi.2017.11.011>
- Ye, C., & Fabbri, D. (2018). Extracting similar terms from multiple EMR-based semantic embeddings to support chart reviews. *Journal of Biomedical Informatics*, 83, 63–72. <https://doi.org/10.1016/j.jbi.2018.05.014>
- Zheng, K., Mei, Q., & Hanauer, D. A. (2011). Collaborative search in electronic health records. *Journal of the American Medical Informatics Association*, 18(3), 282–291. <https://doi.org/10.1136/amiajnl-2011-000009>